

Cadrage discursif du conflit israélo-palestinien dans la presse française

Une approche textométrique des registres « terrorisme » et « génocide » (7 octobre 2023 – février 2026)

Ilyas Hanine

10.05.26

Table des matières

1	Introduction et problématique	2
2	Cadre théorique	2
3	Un trou dans la littérature francophone scientifique	3
4	Méthode	3
5	Note de réflexivité / neutralité	4
6	Chaîne de traitement	4
7	Usage de l'intelligence artificielle	4
8	Constitution du corpus	4
8.1	Fonction de parsing des exports Europresse	4
8.2	Chargement de masse et plan factoriel 2×2	5
8.3	Statistiques descriptives simples du corpus	6
9	Cartographie quantitative dans le temps	7
9.1	Empilement des conditions par journal	7
9.2	Part cumulée du registre “terrorisme seul” normalisée par le flux total	9
9.3	Part cumulée du registre “génocide seul” normalisée par le flux total	10
10	Préparation linguistique : lemmatisation	12
11	Spécificités lexicales (keyness)	14
11.1	Vocabulaire spécifique au registre “terrorisme seul” et au registre “génocide seul”	14
12	Mondes lexicaux : classification hiérarchique descendante	17
12.1	Optimisation du nombre de classes	17
12.2	CHD par condition	19
12.3	Distribution des clusters par journal	23
13	Analyse géométrique : AFC	24
13.1	AFC B — Journaux × Conditions (figure de synthèse)	25
13.2	AFC A — Journaux × Clusters, par condition	26

13.3 AFC D — Journaux × tous les clusters	27
14 Marqueur de rupture temporelle : “désormais”	29
14.1 Fréquence par condition	30
14.2 Série temporelle de “désormais”	30
14.3 Réseau de cooccurrences de “désormais”	31
14.4 Étude de cas : Le Figaro et la “guerre des 12 jours” (juin 2025)	32
15 Conclusion	33
16 Références provisoires	33
17 Annexe : informations de session	34

1 Introduction et problématique

La sociologue Alessia Lefébure de l’École des hautes études en santé publique (EHESP) dans un article de vulgarisation paru dans *The Conversation* nous dit que

“La violence de l’attaque inédite du Hamas contre Israël, puis celle de la riposte de Tsahal dans la bande de Gaza ont déclenché des réactions intenses [...]. Cette polarisation ramène la question israélo-palestinienne au centre des préoccupations”.

Bien que la polarisation dont parle l’auteur ressort du champ académique, en particulier d’une fraction du mouvement étudiant sur les campus américains, nous faisons l’hypothèse que cette polarisation touche également les champs politique et journalistique français. Cette polarisation articule selon nous deux positions discursifs dans la qualification des événements survenus à compter du 7 octobre 2023.

Dans cette recherche, on se propose d’analyser avec des outils d’analyse textuelle, l’ensemble des articles issus de la presse quotidienne française (sept titres ont été retenus : Le Monde, Figaro, L’Humanité, L’Opinion, Le Parisien, La Croix, Libération) à propos du conflit entre Israël et Gaza ouvert à la suite des événements du 7 octobre 2023 contre des civils israéliens.

Il importe que le lecteur ou la lectrice comprenne clairement que cette étude ne vise pas à prendre parti de façon normative sur la qualification juste des événements dont traitent les articles rassemblés dans le corpus. Pas plus il ne cherchera à orienter l’analyse en vue de la recherche de supposés biais entre tel ou tel titre de presse relativement à tel ou tel protagoniste du conflit. Il s’agira bien plutôt d’examiner dans quelle mesure *les champs discursifs* associé à la qualification “terrorisme” et ceux associés à la qualification “génocide”, dans le contexte du conflit israélo-palestinien ouvert par les attaques du 7 octobre 2023, constituent ou non des registres autonomes et structurellement distincts ; et, s’ils se recoupent, suivant quelles logiques éditoriales, thématiques, et temporelles identifiables à partir du corpus ?

2 Cadre théorique

Cette recherche s’inscrit dans la perspective de l’analyse critique du discours développée par Teun van Dijk (1993), pour qui le discours de presse n’est jamais un simple miroir des événements mais une construction qui encode des positions idéologiques. La notion d’ideological square — la valorisation discursive d’un groupe d’appartenance et la dévalorisation symétrique d’un groupe adverse — offre un cadre pour penser la manière dont la qualification d’un même conflit varie selon les orientations éditoriales. Nous mobilisons également la notion de cadrage (framing) telle que la définit Entman (1993), comme opération de sélection et de mise en saillance de certains aspects d’une réalité au détriment d’autres : choisir “terrorisme” ou “génocide” pour qualifier une même séquence relève précisément d’un tel travail de cadrage.

L’analyse de la dynamique temporelle des débats emprunte enfin à Chateauraynaud et Doury (2010) l’attention portée aux marqueurs argumentatifs de rupture, et en particulier à l’adverbe “désormais” comme

indice linguistique de la périodisation construite par les acteurs.

3 Un trou dans la littérature francophone scientifique

Une revue, même partielle et limitée en temps, de la littérature sur le traitement médiatique du conflit israélo-palestinien (pas nécessairement depuis le 7 octobre) fait apparaître un déséquilibre net : les travaux empiriques outillés restent rares dans le paysage français, tandis que dominent les pièces de doctrine, les essais et les contributions de revues intellectuelles.

Dans un article publié dans la rubrique « Échanges » de Questions de communication, Kent et Palmer (2005) distinguent deux formes de « revendications de vérité » qui sous-tendent les critiques adressées à la couverture médiatique. La première repose sur l’affirmation d’une connaissance supérieure des faits, permettant de qualifier un compte rendu de fautif ou de lacunaire ; la seconde, héritée des traditions du framing, de l’agenda-setting et de l’indexing, ne porte aucun jugement sur la vérité des événements mais évalue le décalage entre la performance des médias et leur devoir déontologique de représenter l’ensemble des opinions pertinentes. Cette seconde voie, épistémologiquement plus solide selon les auteurs, est précisément celle qui suppose un appareillage empirique d’envergure, mais qu’aucuns travaux francophones consultés à propos du conflit survenu depuis le 7 octobre n’a été en mesure de déployer. En effet, toujours selon Kent et Palmer, passer de la critique d’événements isolés à un diagnostic sur la couverture cumulative exige, écrivent-ils, « un saut méthodologique de grande envergure », celui qui mène du particulier au général et qui suppose un échantillon aussi représentatif que possible.

Leur contribution illustre par ailleurs une pente propre au débat francophone : la question de “biais” glisse rapidement vers celle de la légitimité de l’État d’Israël, et donc vers la relation, qu’ils qualifient d’inséparable, entre antisionisme et antisémitisme. La discussion s’y déploie ainsi davantage sur le terrain de la philosophie politique et de la déontologie que sur celui de la mesure outillée d’un corpus. **Il ne s’agit absolument pas par cette étude de prétendre ouvrir un espace empiriquement fondé, mais plutôt de suivre l’épistémologie que les auteurs appellent de leur vœux.**

Les rares travaux empiriques récents portant sur la séquence ouverte le 7 octobre 2023 sont, eux, anglophones et centrés sur des terrains non français. En faisant le tri entre les travaux issus revues prédatrices ou relativement moins prestigieuses, nous avons pu recensé deux articles scientifiques. Kozman et Cozma (2025) analysent les titres de cinq agences de presse internationales (AP, Reuters, QNA, TASS et Xinhua) sous l’angle du journalisme de guerre et de paix, et constatent que toutes, à l’exception de l’agence qatarie QNA, privilégient le registre du journalisme de guerre, l’absence de toute qualification explicite y constituant le cas le plus fréquent. Suivant une autre ligne de recherche, El Damanhoury, Saleh et Lebovic (2025) comparent, par analyse critique du discours, la couverture en ligne d’Al Jazeera English et de la BBC, et établissent une différence pas tant dans l’agentivité conférée aux acteurs israéliens et palestiniens (via l’usage de la voie active), que dans le relais par les protagonistes des accusations de « génocide », de « nettoyage ethnique » ou de « terrorisme » portées contre Israël. Plus ancien, Handley (2009) examine la gestion du récit israélo-palestinien dans le New York Times et le Washington Post lorsque l’auteur d’un attentat est israélien, et met au jour une asymétrie dans l’application de la qualification « terroriste » selon l’identité de l’agresseur.

4 Méthode

Nous avons procédé à un recueil de l’ensemble des titres suivant deux clefs logiques : *avec* ou *sans* génocide **ET** *avec* ou *sans* terrorisme. Au total, quatre corpus ont donc été constitués suivant les modalités logiques précédentes. Les articles ont été récupérés depuis la base de données Europresse avec la requête suivante :

“Israël” ET (“Palestine” OU “Gaza” OU “Hamass”) ET / NON ET (“génocide” OU “génocidaire”) ET / NON ET (“terrorisme” OU “terroristes” OU “terroriste”)

Ce croisement définit quatre conditions discursives mutuellement exclusives par construction logique, déclinées par journal en 28 sous-corpus.

Au total, 10852 articles ont été récoltés couvrant la période allant du 7 octobre 2023 au 27 février 2026, la veille du début du conflit entre les Etats-Unis et Israël d'une part, et l'Iran de l'autre. Nous nous sommes fixés cette date pour éviter les empilements thématiques d'articles et conserver une focale sur le conflit Israël-Palestine.

5 Note de réflexivité / neutralité

Il convient d'insister sur le statut de cette analyse : elle porte sur la qualification discursive, c'est-à-dire sur la manière dont la presse nomme et cadre les événements, et non sur la réalité de supposés faits ainsi qualifiés. Déterminer si les événements relèvent ou non, en droit, des catégories de " terrorisme " ou de " génocide " excède le cadre de ce travail et ne ressort probablement pas du travail scientifique.

L'objet est ici la circulation et la distribution de ces qualifications dans l'espace médiatique français. Cette posture descriptive s'accompagne d'une exigence de traçabilité : l'ensemble de la chaîne de traitement est documenté et reproductible, **conformément aux principes FAIR (Findable, Accessible, Interoperable, Reusable)**, de sorte que chaque résultat puisse être réexaminé à partir des données sources.

6 Chaîne de traitement

Le traitement suit une chaîne entièrement réalisée sous R. Les exports HTML d'Europresse sont d'abord analysés pour en extraire le texte intégral et les métadonnées de chaque article (titre, source, date, rubrique). Les textes sont ensuite lemmatisés à l'aide d'udpipe et de son modèle pré-entraîné pour le français (french-gsd), puis filtrés par catégorie grammaticale. La matrice documents-termes ainsi obtenue (quanteda) sert de base aux différentes analyses : séries chronologiques de la couverture, analyse des spécificités lexicales (keyness), classification hiérarchique descendante au sens de Reinert (rainette), analyse factorielle des correspondances (FactoMineR), et étude des marqueurs argumentatifs de rupture temporelle.

7 Usage de l'intelligence artificielle

Le script de scrapping a été réalisé conjointement avec le modèle de langage *Claude*. Le script R a largement été écrit sans l'aide d'intelligence artificielle pour la partie analyse, et en discussion avec le modèle *Claude* pour le nettoyage des données.

8 Constitution du corpus

8.1 Fonction de parsing des exports Europresse

Chaque export HTML Europresse contient une série d'articles sous forme de balises <article>. La fonction ci-dessous extrait, pour chacun, les métadonnées (source, date, rubrique, longueur) et le texte intégral. La date est récupérée depuis le nodoc, plus fiable.

```
parse_europresse_html <- function(filepath, journal, avec_genocide, avec_terrorisme) {  
  
  html <- read_html(filepath, encoding = "UTF-8")  
  articles <- html |> html_elements("article")  
  
  map_dfr(articles, function(art) {  
  
    # --- Métadonnées ---  
    doc_header <- art |> html_element(".DocHeader") |> html_text(trim = TRUE)  
    titre <- art |> html_element(".titreArticleVisu") |> html_text(trim = TRUE)  
    texte <- art |> html_element(".docOcurrContainer") |> html_text(trim = TRUE)  
    nodoc <- art |> html_element(".publiC-lblNodoc") |> html_text(trim = TRUE)
```

```

# --- Date depuis le nodoc (format : news·AAAAMMJJ·XX·...) ---
date_raw <- str_extract(nodoc, "(?<=\\.)\\d{8}(?=\\.)")
date <- if (!is.na(date_raw)) ymd(date_raw) else NA_Date_

# Fallback : date depuis l'en-tête (ex. "Débats, mercredi 8 novembre 2023 ...")
if (is.na(date)) {
  mois_fr <- c("janvier"=1,"février"=2,"mars"=3,"avril"=4,"mai"=5,
               "juin"=6,"juillet"=7,"août"=8,"septembre"=9,
               "octobre"=10,"novembre"=11,"décembre"=12)
  date_match <- str_match(doc_header, "(\\d{1,2})\\s+(\\w+)\\s+(\\d{4})")
  # (.) --> groupe de capture
  if (!is.na(date_match[1])) {
    jour <- as.integer(date_match[2])
    mois <- mois_fr[tolower(date_match[3])]
    annee <- as.integer(date_match[4])
    date <- if (!is.na(mois)) ymd(paste(annee, mois, jour)) else NA_Date_
  }
}

rubrique <- str_extract(doc_header, "[^,]+")
nb_mots <- as.integer(str_extract(doc_header, "\\d+(?=\\s+mots)"))

tibble(
  journal, avec_genocide, avec_terrorisme,
  date, rubrique, nb_mots, titre,
  texte = str_squish(texte),
  nodoc
)
})
}

```

8.2 Chargement de masse et plan factoriel 2×2

La convention de nommage des fichiers (Journal_avecOUsans_avecOUsans.HTML) encode directement les deux conditions croisées. Les quatre cellules sont mutuellement exclusives par construction (cf. logique ET / NON ET des requêtes Euroresse).

```

charger_corpus <- function() {

  fichiers <- list.files(pattern = "\\..HTML$|\\.html$", full.names = TRUE)

  map_dfr(fichiers, function(f) {
    nom <- tools::file_path_sans_ext(basename(f))
    parties <- str_split(nom, "_")[[1]]

    journal <- parties[1]
    avec_genocide <- parties[2] == "avec"
    avec_terrorisme <- parties[3] == "avec"

    message("Parsing : ", nom)
    parse_euroresse_html(f, journal, avec_genocide, avec_terrorisme)
  })
}

```

```

corpus <- charger_corpus()

# Nettoyage et variables dérivées
corpus <- corpus |>
  filter(!is.na(date)) |>
  mutate(
    annee_mois = floor_date(date, "month"),
    semaine    = floor_date(date, "week"),
    condition  = case_when(
      avec_genocide & avec_terrorisme ~ "génocide + terrorisme",
      avec_genocide & !avec_terrorisme ~ "génocide seul",
      !avec_genocide & avec_terrorisme ~ "terrorisme seul",
      TRUE ~ "ni génocide ni terrorisme"
    ),
    condition = factor(condition, levels = c(
      "génocide + terrorisme", "génocide seul",
      "terrorisme seul", "ni génocide ni terrorisme"
    ))
  )
)

```

8.3 Statistiques descriptives simples du corpus

```

library(janitor)
# Vérification de cohérence : pas de doublon inter-conditions
doublons <- corpus |> group_by(nodoc) |> filter(n() > 1)
cat("Doublons nodoc :", nrow(doublons), "\n")

## Doublons nodoc : 0

# Effectifs par journal et condition
corpus |>
  count(journal, condition) |>
  tidyr::pivot_wider(names_from = condition, values_from = n, values_fill = 0) |>
  adorn_totals(c("row", "col"))

```

```

##      journal génocide + terrorisme génocide seul terrorisme seul
##      Croix                17             63             232
##      Figaro               105             93             968
##      Humanite             100            345             239
##      Liberation            67             95             437
##      Monde                166            218             911
##      Opinion              40             40             264
##      Parisien              22             37             465
##      Total                517            891            3516
## ni génocide ni terrorisme Total
##                        853  1165
##                        970  2136
##                        677  1361
##                        799  1398
##                       1687  2982
##                        359   703
##                        583  1107
##                       5928 10852

```

Au total, sur toute la période couverte par le corpus, une large majorité des articles traitant du conflit israélo-palestinien ne font pas usage des termes de génocide ou de terrorisme (5928 sur un total de 10852). Le sous-corpus avec le moins d'articles (~ 5 % du total) est celui contenant à la fois les familles morphologiques génocide et terrorisme (telles que définies dans la requête Europresse). Enfin, les articles contenant la famille terrorisme à l'exclusion de la famille génocide sont environ quatre fois plus nombreux que ceux dont la modalité logique est inversée.

Cette première perspective doit à présent faire l'objet d'une étude dans le temps de l'occurrence des mots.

9 Cartographie quantitative dans le temps


9.1 Empilement des conditions par journal

```
series_pct <- corpus |>
  filter(!is.na(date), !is.na(condition)) |>
  group_by(journal, annee_mois, condition) |>
  summarise(n = n(), .groups = "drop") |>
  # Compléter les cellules manquantes avec 0 avant de calculer les %
  complete(journal, annee_mois, condition, fill = list(n = 0)) |>
  group_by(journal, annee_mois) |>
  mutate(
    total = sum(n),
    pct = if_else(total == 0, 0, n / total * 100)
  ) |>
  ungroup()

palette_conditions <- c(
  "génocide + terrorisme" = "#c0392b",
  "génocide seul"         = "#e67e22",
  "terrorisme seul"       = "#2980b9",
  "ni génocide ni terrorisme" = "#bdc3c7"
)

ggplot(series_pct, aes(x = annee_mois, y = pct, fill = condition)) +
  geom_area(alpha = 0.9, position = "stack") +
  facet_wrap(~ journal, ncol = 2) +
  scale_fill_manual(values = palette_conditions) +
  scale_x_date(date_labels = "%b %Y", date_breaks = "3 months") +
  scale_y_continuous(labels = scales::percent_format(scale = 1)) +
  labs(
    title = "Cadrage discursif génocide/terrorisme par journal (oct. 2023 - fév. 2026)",
    subtitle = "Part de chaque condition discursive dans le total mensuel d'articles",
    x = NULL, y = "% d'articles", fill = "Condition lexicale"
  ) +
  theme_minimal(base_size = 11) +
  theme(
    axis.text.x = element_text(angle = 45, hjust = 1),
    legend.position = "bottom",
    strip.text = element_text(face = "bold")
  )
```

Cadrage discursif génocide/terrorisme par journal (oct. 2023 – fév. 2026)
Part de chaque condition discursive dans le total mensuel d'articles



L'examen par titre révèle des structures de cadrage nettement contrastées. Le fond gris — les articles ne mobilisant aucune des deux familles — domine quasiment partout, sur toute la séquence temporelle analysée. On relève néanmoins des différences importantes entre les titres : il occupe l'essentiel de la surface à La Croix

et au Parisien, tandis qu'il se réduit sensiblement au Figaro, où la famille terrorisme (en bleu) occupe une part visuellement plus importante et durable comparé aux autres titres. L'Humanité présente le profil inverse au Figaro. En outre, c'est le seul titre où la famille génocide (en orange) atteint une surface comparable, voire supérieure, à celle de la famille terrorisme, et ce de façon croissante sur la seconde moitié de la période.

La condition conjointe — articles mobilisant à la fois les deux familles (en rouge) — demeure marginale dans tous les titres et sur toute la période, confirmant à l'échelle mensuelle ce que les effectifs globaux indiquaient : la coprésence des deux qualifications dans un même article est rare. Elle connaît néanmoins quelques saillies ponctuelles, notamment deux pics nets en mai 2025 chez Libération et au Figaro, qui mériteraient un examen rapproché. On observe enfin que la part de la famille terrorisme tend à aussi à se renforcer ponctuellement chez plusieurs titres à partir du printemps 2025, ce qui invite à examiner plus finement la dynamique temporelle des occurrences.

9.2 Part cumulée du registre “terrorisme seul” normalisée par le flux total

Cette figure rapporte, pour chaque journal, le cumul des articles “terrorisme seul” au cumul de **tous** ses articles depuis le 7 octobre 2023 jusqu'à la date considéré. L'axe vertical n'est pas contraint à 100 % afin de préserver la lisibilité.

```
library(zoo)
library(patchwork)


# Flux total cumulé par journal (toutes conditions)
total_par_journal <- corpus |>
  filter(!is.na(date)) |>
  group_by(date, journal) |>
  summarise(n_total = n(), .groups = "drop") |>
  complete(date = seq(min(date), max(date), by = "day"),
            journal, fill = list(n_total = 0)) |>
  arrange(journal, date) |>
  group_by(journal) |>
  mutate(n_total_cum = cumsum(n_total)) |>
  ungroup()

# Flux "terrorisme seul" cumulé, normalisé par le flux total par journal
series_terrorisme_norm <- corpus |>
  filter(!is.na(date), condition == "terrorisme seul") |>
  group_by(date, journal) |>
  summarise(n = n(), .groups = "drop") |>
  complete(date = seq(min(corpus$date, na.rm = TRUE),
                      max(corpus$date, na.rm = TRUE), by = "day"),
            journal, fill = list(n = 0)) |>
  arrange(journal, date) |>
  group_by(journal) |>
  mutate(n_cum = cumsum(n)) |>
  ungroup() |>
  left_join(total_par_journal |> select(date, journal, n_total_cum),
            by = c("date", "journal")) |>
  mutate(pct_cum = if_else(n_total_cum > 0, n_cum / n_total_cum * 100, 0))

journaux <- sort(unique(series_terrorisme_norm$journal))
palette <- setNames(
  colorRampPalette(RColorBrewer::brewer.pal(8, "Set2"))(length(journaux)),
  journaux
)
```

```
p1_terr <- ggplot(series_terrorisme_norm, aes(x = date, y = pct_cum, color = journal)) +
  geom_line(linewidth = 0.9) +
  scale_color_manual(values = palette) +
  scale_x_date(date_labels = "%b %Y", date_breaks = "2 months") +
  scale_y_continuous(labels = scales::label_percent(scale = 1, suffix = " %")) +
  labs(
    title = "Part cumulée des articles 'terrorisme seul' dans la couverture totale",
    subtitle = "% cumulé propre à chaque journal depuis le 7 octobre 2023",
    x = NULL, y = "% cumulé du flux total", color = NULL
  ) +
  theme_minimal(base_size = 11) +
  theme(legend.position = "bottom", plot.title = element_text(face = "bold"))
```

p1_terr



Au 7 octobre 2023, une écrasante nette des articles du corpus pour chacun des titres de presse, quoi que dans des proportions variables, relève du sous-corpus “terrorisme seul”. Ce flux cumulé se stabilise à partir de l’été 2024 pour atteindre une valeur stationnaire comprise entre 20 % de l’ensemble des articles en février 2026 pour L’Humanité ou le journal La Croix, et jusqu’à 45 % de l’ensemble des articles à cette date pour le Figaro.

9.3 Part cumulée du registre “génocide seul” normalisée par le flux total

Cette figure rapporte, pour chaque journal, le cumul des articles “génocide seul” au cumul de **tous** ses articles depuis le 7 octobre 2023. L’axe vertical n’est pas contraint à 100 % afin de préserver la lisibilité.

```

# Flux "génocide seul" cumulé, normalisé
series_genocide_norm <- corpus |>
  filter(!is.na(date), condition == "génocide seul") |>
  group_by(date, journal) |>
  summarise(n = n(), .groups = "drop") |>
  complete(date = seq(min(corpus$date, na.rm = TRUE),
                      max(corpus$date, na.rm = TRUE), by = "day"),
           journal, fill = list(n = 0)) |>
  arrange(journal, date) |>
  group_by(journal) |>
  mutate(n_cum = cumsum(n)) |>
  ungroup() |>
  left_join(total_par_journal |> select(date, journal, n_total_cum),
            by = c("date", "journal")) |>
  mutate(pct_cum = if_else(n_total_cum > 0, n_cum / n_total_cum * 100, 0))

journaux <- sort(unique(series_genocide_norm$journal))
palette <- setNames(
  colorRampPalette(RColorBrewer::brewer.pal(8, "Set2"))(length(journaux)),
  journaux
)


# Données morts cumulés (Gaza)
casualties <- readr::read_csv("casualties_daily.csv", show_col_types = FALSE) |>
  mutate(date = as.Date(report_date)) |>
  select(date, killed_cum) |>
  filter(!is.na(killed_cum))

p1 <- ggplot(series_genocide_norm, aes(x = date, y = pct_cum, color = journal)) +
  geom_line(linewidth = 0.9) +
  scale_color_manual(values = palette) +
  scale_x_date(date_labels = "%b %Y", date_breaks = "2 months") +
  scale_y_continuous(labels = scales::label_percent(scale = 1, suffix = "%")) +
  labs(
    title = "Part cumulée des articles 'génocide seul' dans la couverture totale",
    subtitle = "% cumulé propre à chaque journal depuis le 7 octobre 2023",
    x = NULL, y = "% cumulé du flux total", color = NULL
  ) +
  theme_minimal(base_size = 11) +
  theme(axis.text.x = element_blank(), axis.ticks.x = element_blank(),
        legend.position = "bottom", plot.title = element_text(face = "bold"))

p2 <- ggplot(casualties, aes(x = date, y = killed_cum)) +
  geom_area(fill = "plum", alpha = 0.35) +
  geom_line(color = "purple4", linewidth = 0.8) +
  scale_x_date(date_labels = "%b %Y", date_breaks = "2 months") +
  scale_y_continuous(labels = scales::label_comma()) +
  labs(title = "Statistiques de morts palestiniens dans le conflit avec Israël depuis le 7 octobre",
       subtitle = "Source : données du 'United Nations Office for the Coordination of Humanitarian Affa",
       x = NULL, y = NULL) +
  theme_minimal(base_size = 11) +
  theme(axis.text.x = element_text(angle = 45, hjust = 1),
        plot.title = element_text(face = "bold"))

```

```
p1 / p2 + plot_layout(heights = c(2, 1))
```



Rapportée à la couverture totale de chaque titre, la part cumulée des articles relevant du sous-corpus "génocide seul" fait apparaître une hiérarchie stable et fortement contrastée entre les journaux. L'Humanité se détache nettement de l'ensemble : la part y croît rapidement dès l'automne 2023, dépasse 15 % au printemps 2024, puis se stabilise entre l'été 2024 et l'été 2025, avant de progresser de nouveau jusqu'à se stabiliser autour de 25 % à partir de décembre 2025 jusqu'à la fin de la période. Les six autres titres demeurent groupés dans une bande plus basse, comprise entre 3 % et 7 % à partir de juin 2024 et jusqu'à la fin de la période. Le Monde occupe le haut de ce peloton et Le Parisien le bas. Au-delà de ces écarts de niveau, la dynamique est commune à tous : après une phase de montée durant les premiers mois, les courbes s'infléchissent et tendent vers un palier à partir de l'été 2024, signe, si l'on veut, que le rythme d'incorporation du terme "génocide" se stabilise relativement à la couverture générale du conflit.

La mise en regard avec la courbe des pertes humaines cumulées appelle la prudence : on rapproche ici une variable de flux discursif d'une variable de stock, à seule fin descriptive. On peut toutefois noter que la stabilisation des parts cumulées à partir de l'été 2024 intervient alors que le bilan humain tel que donné par les sources mobilisées, lui, continue de croître.

10 Préparation linguistique : lemmatisation

La lemmatisation ramène chaque mot du corpus à sa forme canonique. Cette étape est nécessaire parce que l'analyse statistique d'un texte traite chaque forme distincte comme un terme séparé : sans regroupement, le poids d'une notion se trouve dispersé entre ses variantes flexionnelles, ce qui affaiblit la détection des régularités lexicales.

On distingue la lemmatisation de la simple racinisation (stemming), qui tronque mécaniquement les mots à

un radical approximatif. La racinisation est plus rapide mais produit des formes souvent illisibles et regroupe parfois des termes de sens différents. La lemmatisation s'appuie au contraire sur une analyse grammaticale : elle identifie la catégorie de chaque mot (nom, verbe, adjectif, adverbe...) avant de lui attribuer son lemme. Cette information grammaticale permet ensuite de filtrer le corpus sur les catégories pertinentes pour l'analyse du contenu — typiquement les noms, verbes, adjectifs et noms propres — en écartant les mots-outils (déterminants, prépositions, conjonctions) a priori dépourvus de valeur thématique (cette dernière remarque serait probablement à tempérer suivant le corpus).

Le traitement est réalisé avec `udpipe` et son modèle pré-entraîné pour le français (`french-gsd`), qui annote chaque mot en contexte. Le coût de cette précision est un temps de calcul plus élevé que la racinisation, mais il est justifié ici par la finesse requise pour l'interprétation qualitative des mondes lexicaux et des spécificités de vocabulaire qui suivent.

```
library(udpipe)
# Téléchargement (une seule fois)
udpipe_download_model(language = "french", model_dir = "~/udpipe_models")

# NOTE : chunk coûteux (~30-50 min). Exécuté une fois, résultat sérialisé en .rds.
# eval=TRUE uniquement pour régénérer lemmes_raw.rds depuis zéro.

ud_model <- udpipes_load_model("~/udpipe_models/french-gsd-ud-2.5-191206.udpipe")

library(future.apply)
plan(multisession, workers = parallel::detectCores() - 1)

chunk_size <- 500
n_chunks <- ceiling(nrow(corpus) / chunk_size)

lemmes_raw <- future_lapply(seq_len(n_chunks), function(i) {
  idx <- ((i - 1) * chunk_size + 1) : min(i * chunk_size, nrow(corpus))
  batch <- corpus[idx, ]
  udpipes_annotate(ud_model, x = batch$texte, doc_id = batch$nodoc, trace = 100) |>
    as.data.frame(detailed = FALSE)
}) |> bind_rows()

saveRDS(lemmes_raw, "lemmes_raw.rds")

# Rechargement du résultat lemmatisé (évite de relancer udpipes)
lemmes_raw <- readRDS("lemmes_raw.rds")
cat("Tokens annotés :", nrow(lemmes_raw), "\n")
```

```
## Tokens annotés : 11773907
```

```
library(dplyr)
library(stringr)

stopwords_fr <- c(
  stopwords::stopwords("fr", source = "snowball"),
  stopwords::stopwords("fr", source = "stopwords-iso"),
  "avoir", "être", "faire", "dire", "aller", "pouvoir", "devoir", "vouloir", "falloir",
  "agir", "permettre", "an", "année", "jour", "mois", "semaine",
  "selon", "après", "avant", "lors", "suite", "depuis"
) |> unique()

lemmes_clean <- lemmes_raw |>
```

```

filter(
  upos %in% c("NOUN", "ADJ", "VERB", "PROPN"),
  nchar(lemma) > 2,
  !grepl("[0-9[:punct:]]", lemma),
  !tolower(lemma) %in% stopwords_fr,
  lemma != "_"
) |>
mutate(lemma = tolower(lemma))

textes_lemmes <- lemmes_clean |>
group_by(doc_id) |>
summarise(texte_lemme = paste(lemma, collapse = " "), .groups = "drop") |>
rename(nodoc = doc_id)

corpus_lemme <- corpus |>
select(nodoc, journal, condition, date, annee_mois,
  avec_genocide, avec_terrorisme) |>
left_join(textes_lemmes, by = "nodoc") |>
filter(!is.na(texte_lemme), nchar(texte_lemme) > 50)

cat("Documents conservés :", nrow(corpus_lemme), "\n")

## Documents conservés : 10777

library(quanteda)
library(quanteda.textstats)
library(quanteda.textplots)

corpus_q <- corpus(corpus_lemme, text_field = "texte_lemme", docid_field = "nodoc")

toks <- corpus_q |>
tokens(remove_punct = TRUE, remove_numbers = TRUE) |>
tokens_remove(stopwords_fr, padding = FALSE)

dfm_full <- toks |>
dfm() |>
dfm_trim(min_termfreq = 10, min_docfreq = 5)

cat("DFM :", ndoc(dfm_full), "documents ×", nfeat(dfm_full), "termes\n")

## DFM : 10777 documents × 17236 termes

```

11 Spécificités lexicales (keyness)

11.1 Vocabulaire spécifique au registre “terrorisme seul” et au registre “génocide seul”


```

keyness_genocide <- dfm_full |>
textstat_keyness(
  target = docvars(dfm_full, "condition") == "terrorisme seul",
  measure = "lr"
)

textplot_keyness(keyness_genocide, n = 30, color = c("#e74c3c", "#2980b9")) +


```

```
labs(title = "Termes spécifiques - 'terrorisme seul' vs reste du corpus") +
theme_minimal(base_size = 11)
```



```
keyness_genocide <- dfm_full |>
textstat_keyness(
  target = docvars(dfm_full, "condition") == "génocide seul",
  measure = "lr"
)

textplot_keyness(keyness_genocide, n = 30, color = c("#e74c3c", "#2980b9")) +
labs(title = "Termes spécifiques - 'génocide seul' vs reste du corpus") +
theme_minimal(base_size = 11)
```



Les deux analyses de spécificités (calculées par log-likelihood, le terme de référence étant le reste du corpus) dessinent deux univers lexicaux nettement séparés. Le sous-corpus “terrorisme seul” se caractérise par un vocabulaire de l’événement et de l’acte : autour du pivot terroriste se regroupent attentat, attaque, otage, couteau, assaillant, djihadiste, islamiste, ainsi qu’un ancrage français marqué (Arras, Paty, Samuel, France) et un pôle politique intérieur (Nupes, Mélenchon, Darmanin, LFI, insoumis, député). Le sous-corpus “génocide seul” mobilise un vocabulaire de la qualification juridique et institutionnelle : autour de génocide se rangent crime, CIJ, cour, international, droit, justice, pénal, CPI, juge, ordonnance, complicité, auxquels s’ajoute un pôle référentiel propre (Pretoria, Afrique du Sud, apartheid, Shoah, boycott).

Attention, la symétrie des termes en position négative appelle une précaution de lecture. Le mot le plus sous-représenté du corpus « terrorisme seul » est génocide, et réciproquement, le terme le plus fui par le corpus « génocide seul » est terroriste : mais cette répulsion est ici tautologique, puisqu’elle découle directement de la construction même des sous-corpus, définis par la présence d’un lexème à l’exclusion de l’autre. La symétrie inversée des pôles négatifs des deux analyses ne sont donc pas interprétables comme un résultat immédiat. A priori, ils ne font que refléter la requête. On relèvera deux observations intéressantes néanmoins : l’analyse du sous-corpus “terrorisme” semble faire apparaître une opposition avec un univers lexical de la politique américaine (trump, mamdani, université, kamala, dollar, etc.) ; l’analyse du sous-corpus “génocide” dessine une opposition avec un univers lexical qui intersecte la géopolitique du Moyen-Orient (Tsalal, Iran, Hezbollah, Liban, etc.) et un langage guerrier (frappe, attentat, missile, chef, armée, etc.).

12 Mondes lexicaux : classification hiérarchique descendante

La classification hiérarchique descendante (CHD) au sens de Reinert (1993), développée dans les années 1980 et popularisée par les logiciels Alceste puis IRaMuTeQ, est l'une des méthodes de référence de la textométrie française. Son principe est de partitionner le corpus de façon itérative : à chaque étape, l'ensemble est scindé en deux classes maximisant le contraste de leurs vocabulaires respectifs, l'opération étant répétée jusqu'à obtenir le nombre de classes souhaité. Chaque classe ainsi obtenue rassemble des énoncés qui partagent un même profil lexical.

L'unité d'analyse n'est pas le document entier mais le segment de texte, fragment de quelques dizaines de mots découpé automatiquement à l'intérieur de chaque article. Ce choix, hérité d'Alceste, permet de saisir des cohérences lexicales locales : un même article peut ainsi relever de plusieurs mondes lexicaux selon les passages. Les classes présentées dans les dendrogrammes qui suivent sont donc des regroupements de segments, et leurs effectifs s'expriment en nombre de segments classés, non en nombre d'articles. La mise en œuvre s'appuie sur le package *rainette* qui est l'implémentation R de l'algorithme de Reinert.

12.1 Optimisation du nombre de classes

Le nombre de classes k n'est pas imposé par la méthode : une CHD peut être coupée à n'importe quelle hauteur du dendrogramme. Pour le fixer sur des critères explicites plutôt qu'arbitrairement, on teste toutes les valeurs de k de 2 à 10 sur chaque sous-corpus, évaluées par deux indicateurs. Le premier est la proportion de segments classés : la méthode de Reinert écarte les segments dont le profil lexical est trop atypique pour être rattaché de façon stable, et un k trop élevé fait chuter ce taux. Le second mesure la séparation entre classes. Rappelons que la classification de Reinert procède, à chaque division, par une analyse factorielle des correspondances du tableau lexical binaire (une matrice avec en ligne les segments du corpus, et en colonne, les termes) et scinde en deux classes initiales selon la première valeur propre avec un niveau de seuil fixé par l'analyste (proche de 0). La dispersion qu'elle optimise est donc une inertie au sens du ², et non une inertie euclidienne. En pratique, nous approximations cette séparation par la hauteur de la dernière agrégation du dendrogramme.

L'arbitrage procède par recherche d'un coude. À mesure que k augmente, la séparation inter-classe croît mécaniquement puisque diviser davantage distingue toujours un peu mieux. Mais le gain marginal décroît : passé un seuil, ajouter une classe ne fait que fractionner des regroupements déjà homogènes sans révéler de structure nouvelle. Le coude est le point d'inflexion où la courbe s'aplatit ; il identifie le k qui capte l'essentiel de la structure lexicale sans "sur-segmenter". On retient pour chaque condition le k situé à ce coude, sous réserve que la proportion de segments classés y reste élevée — soit $k = 6$ pour les deux corpus mobilisant « génocide » et $k = 5$ pour les deux autres.

```
library(rainette)

optimiser_k <- function(dfm_cond, k_min = 2, k_max = 10) {
  docvars(dfm_cond, "doc_id") <- docnames(dfm_cond)
  map_dfr(k_min:k_max, function(k) {
    set.seed(42)
    chd <- rainette(dfm_cond, k = k, min_segment_size = 3, doc_id = "doc_id")
    classes <- cutree(chd, k = k)
    tibble(k,
            pct_classes = mean(!is.na(classes)) * 100,
            inertie      = tail(chd$height, 1))
  })
}

conditions <- c("génocide seul", "terrorisme seul",
               "génocide + terrorisme", "ni génocide ni terrorisme")

stats_k <- map_dfr(conditions, function(cond) {
```

```


dfm_cond <- dfm_full |>
  dfm_subset(condition == cond) |>
  dfm_trim(min_termfreq = 5, min_docfreq = 3)
optimiser_k(dfm_cond) |> mutate(condition = cond)
})

pa <- ggplot(stats_k, aes(x = k, y = inertie, color = condition)) +
  geom_line(linewidth = 0.9) + geom_point(size = 2) +
  scale_color_manual(values = palette_conditions) +
  scale_x_continuous(breaks = 2:10) +
  labs(title = "Inertie intra-cluster selon k",
       subtitle = "Coude = k optimal", x = "k", y = "Chi2 moyen", color = NULL) +
  theme_minimal(base_size = 11) +
  theme(plot.title = element_text(face = "bold"), legend.position = "bottom")

pb <- ggplot(stats_k, aes(x = k, y = pct_classes, color = condition)) +
  geom_line(linewidth = 0.9) + geom_point(size = 2) +
  geom_hline(yintercept = 80, linetype = "dashed", color = "red", linewidth = 0.5) +
  scale_color_manual(values = palette_conditions) +
  scale_x_continuous(breaks = 2:10) +
  scale_y_continuous(labels = scales::label_percent(scale = 1)) +
  labs(title = "% de segments classés selon k", x = "k", y = "% classés", color = NULL) +
  theme_minimal(base_size = 11) +
  theme(plot.title = element_text(face = "bold"), legend.position = "bottom")

pa / pb + plot_layout(guides = "collect") & theme(legend.position = "bottom")

```



[À COMPLÉTER — Choix de k] Justifier le k retenu pour chaque condition (k = 6 pour les corpus "génocide", k = 5 pour "terrorisme seul" et "ni l'un ni l'autre") à partir des coudes d'inertie et du taux de classement.

12.2 CHD par condition

```
params_k <- list(
  "génocide seul" = 6,
  "terrorisme seul" = 5,
  "génocide + terrorisme" = 6,
  "ni génocide ni terrorisme" = 5
)

ordre_journaux <- c("Humanite", "Liberation", "Monde",
  "Croix", "Parisien", "Figaro", "Opinion")

analyser_condition <- function(condition_cible, k) {
  dfm_cond <- dfm_full |>
    dfm_subset(condition == condition_cible) |>
    dfm_trim(min_termfreq = 5, min_docfreq = 3)
  docvars(dfm_cond, "doc_id") <- docnames(dfm_cond)

  set.seed(42)
```

```

chd <- rainette(dfm_cond, k = k, min_segment_size = 3, doc_id = "doc_id")

assignation <- tibble(nodoc = docnames(dfm_cond), cluster = cutree(chd, k = k))
corpus_cond <- corpus_lemme |>
  filter(condition == condition_cible) |>
  left_join(assignation, by = "nodoc")

list(chd = chd, dfm = dfm_cond, corpus = corpus_cond, assignation = assignation, k = k)
}

resultats <- imap(params_k, function(k, condition) analyser_condition(condition, k))


```

12.2.1 CHD “Génocide seul” (k=6)

```

rainette_plot(resultats[["génocide seul"]], $chd,
  resultats[["génocide seul"]], $dfm,
  k = 6, n_terms = 15, measure = "chi2", show_negative = FALSE) +
  ggplot2::ggtitle("CHD - sous-corpus « génocide seul » (k = 6)")

```



NULL

La première division de l’arbre, la plus structurante, oppose deux grands ensembles. D’un côté (~40 %), un bloc qui rapporte le conflit à la scène française ou occidentale (clusters 1 et 2) ; de l’autre (~60 %), un bloc tourné vers le terrain, les acteurs internationaux et leur traitement institutionnel (clusters 3 à 6). Cette opposition primaire organise l’ensemble du sous-corpus.


Le premier bloc se subdivise en deux mondes proches. Le cluster 1 réunit un vocabulaire culturel et mémoriel (film, artiste, cinéma, théâtre, Shoah, histoire) : le conflit y est abordé par le prisme de la création et de la mémoire. Le cluster 2 relève de la politique intérieure et des mobilisations (étudiant, candidat, LFI, Mélenchon, gauche, université), avec un ancrage à la fois français et sur les campus américains. Leur regroupement indique une proximité lexicale : ce sont probablement deux déclinaisons du traitement occidental de la question.

Le second bloc se déploie en quatre classes. Le cluster 3, qui se détache le premier, est humanitaire (Gaza, hôpital, aide, évacuation, famine, Rafah, enfant) avec un registre le plus directement descriptif de la situation

sur le terrain. Les trois classes restantes forment un sous-ensemble plus institutionnel : le cluster 4 couvre la géopolitique (Netanyahou, paix, Trump, Washington, Iran, Arabie), le cluster 5, de faible effectif (3 %), correspond à un événement circonscrit, l'épisode de la flottille (flottille, navire, Espagne, Sánchez), et le cluster 6 est juridique (crime, cour, CIJ, CPI, juge, droit, pénal). C'est dans cette seule dernière classe que le terme « génocide » occupe une position centrale ; dans les cinq autres, il demeure périphérique, subordonné à un registre culturel, politique, humanitaire ou diplomatique. **Le terme entre donc dans la presse française d'abord comme catégorie juridique, et non comme description 'directe' des faits.**

12.2.2 CHD "Terrorisme seul" (k=5)

```
rainette_plot(resultats[["terrorisme seul"]], $chd,
              resultats[["terrorisme seul"]], $dfm,
              k = 5, n_terms = 15, measure = "chi2", show_negative = FALSE)
```




La division primaire oppose, d'un côté (~64 %), un ensemble consacré au conflit lui-même et à son théâtre régional (clusters 3 à 5), de l'autre un bloc rapportant la question à la scène intérieure française dans un registre politique (cluster 1) et social (cluster 2). On retrouve donc, comme pour « génocide seul », une partition de premier niveau entre le conflit in situ et son traitement domestique.

Dans le second bloc, les clusters 3 et 4 se détachent : ils couvrent les dimensions géopolitique et militaire avec une focale élargie sur le Moyen-Orient dans le cluster majoritaire (cluster 3 : Iran, iranien, Hezbollah, Téhéran, nucléaire, missile, houthiste, Syrie, Liban, Yémen). Le cluster 4 concerne plus directement le conflit israélo-palestinien (Netanyahou, ministre, Hamas, accord, plan, otag). Le cluster 5 est plus narratif ou descriptif, centré sur les événements concrets et leurs protagonistes civils (festival, hôpital, kibboutz, Gaza, maison, enfant, famille).

Le premier bloc réunit deux mondes français. Le cluster 1 est largement déterminé par la dimension de politique partisane en France (parti, Marine, Fare, Assemblée, LFI, Mélenchon), avec une présence plus importante des termes relevant de la politique partisane affiliée à gauche (Nupes, etc.). Le cluster 2 ressort plus d'une dimension socio-politique et articule questions religieuses (juif, musulman) dans ses aspects agonistiques (haine), et les questions de sécurité intérieure (Arras, enseignant, attentat).

12.2.3 CHD “Génocide + terrorisme” (k=6)

```
rainette_plot(resultats[["génocide + terrorisme"]])$chd,
              resultats[["génocide + terrorisme"]])$dfm,
              k = 6, n_terms = 15, measure = "chi2", show_negative = FALSE)
```




Bien que rare en effectifs, la condition conjointe présente une structure nette. La division primaire oppose un bloc consacré au conflit, à sa diplomatie et à sa qualification juridique (clusters 1 à 3) à un bloc entièrement dédié aux espaces de contestation, culturels (on dira ça faute de meilleur qualificatif), universitaires et politiques (clusters 4 à 6).

Dans le premier bloc, le cluster 1 relève du terrain militaire (israélien, Gaza, armée, enclave, soldat, frappe, hôpital, militaire). Les clusters 2 et 3, même s'ils ne sont pas quantitativement regroupés, en constituent le versant institutionnel : le cluster 2 est diplomatique (pays, Netanyahou, Trump, accord, Qatar, Arabie, Turquie), le cluster 3 est juridique (crime, CPI, cour, international, génocide, pénal, justice, La Haye). On retrouve ici le pôle juridique déjà identifié dans « génocide seul » : la qualification pénale est le canal récurrent par lequel le terme « génocide » s'installe.

Le second bloc est tout entier consacré à la politisation du conflit en France et aux Etats-Unis. Le cluster 4 mêle débat intellectuel et tensions 'intercommunautaires' (juif, antisémitisme, BHL, musulman, histoire, religion, enseigner). Les clusters 5 et 6 dénotent deux arènes bien identifiées. Le cluster 5 concerne la contestation des campus américains (Cornell, Columbia, Stanford, campus, Harvard) ; le cluster 6, la scène partisane française (LFI, Rima Hassan, insoumis, député, socialiste, gauche, étudiant). La coprésence des deux qualifications apparaît ainsi étroitement liée aux espaces de polémique — intellectuelle, universitaire, partisane. Nommer simultanément “génocide” et “terrorisme” semble dans ce cas rapporter sur un mode indirect une controverse sur la juste qualification des événements endossés par les acteurs.

12.2.4 CHD “Ni génocide ni terrorisme” (k=5)

```
rainette_plot(resultats[["ni génocide ni terrorisme"]])$chd,
              resultats[["ni génocide ni terrorisme"]])$dfm,
              k = 5, n_terms = 15, measure = "chi2", show_negative = FALSE)
```



Pour rappel, le sous-corpus le plus volumineux est celui qui traite du conflit sans recourir à aucune des deux qualifications. Dans ce sous-corpus, la première opposition est identique aux analyses précédentes. Un bloc consacré au conflit et à sa région (cluster 1-3) et un bloc consacré à la scène intérieure française (clusters 5 et 6). Ici on notera que ce bloc est exclusivement français, comparé aux autres sous-corpus dont les analyses faisaient apparaître l'émergence de scène étatsunienne. On conserve toutefois la même tension structurante que dans les autres conditions : débat domestique d'un côté, situation sur le terrain de l'autre.

Le second bloc réunit deux mondes français proches. Le cluster 5 relève de la politique partisane (Mélenchon, LFI, député, gauche, Nupes, insoumis, socialiste, Le Pen, parti) ; le cluster 4 est centré sur des aspects culturels et notamment la place de la culture juive dans la vie intellectuelle en France (juif, artiste, Arendt, vie).

Le premier bloc se déploie en trois classes. Le cluster 1 porte sur les conflits au Moyen-Orient entourant la situation en Israël et à Gaza (Yémen, militaire, Iran, Hezbollah, Houthiste, Syrie). Le cluster 2 relève des dimensions diplomatiques du conflit israélo-palestinien (Netanyahou, Trump, paix, négociation, accord). Enfin, le cluste 3 est beaucoup plus descriptif et semble focalisé sur la situation humanitaire à Gaza (bande, Gaza, hôpital, habitant, bombardement, enfant).

12.3 Distribution des clusters par journal


```
plot_clusters_journal <- function(res, condition_cible) {
  res$corpus |>
    group_by(cluster, journal) |>
    summarise(n = n(), .groups = "drop") |>
    group_by(journal) |>
    mutate(pct = n / sum(n) * 100) |>
    ungroup() |>
    mutate(cluster = factor(cluster),
           journal = factor(journal, levels = ordre_journaux)) |>
    ggplot(aes(x = journal, y = pct, fill = cluster)) +
    geom_col(position = "stack", alpha = 0.9) +
    scale_fill_brewer(palette = "Set2") +
    scale_y_continuous(labels = scales::label_percent(scale = 1)) +
    labs(title = paste0("Clusters CHD par journal - '", condition_cible, "'"),
```

```

x = NULL, y = "% des articles du journal", fill = "Cluster") +
theme_minimal(base_size = 11) +
theme(axis.text.x = element_text(angle = 45, hjust = 1),
      plot.title = element_text(face = "bold"), legend.position = "bottom")
}

plot_clusters_journal(resultats[["génocide seul"]], "génocide seul")

```



Ce travail étant en cours, les analyses qui suivent n'ont pas encore fait l'objet de commentaires stabilisés mais sont ouvertes à l'étude.

13 Analyse géométrique : AFC

Les classifications précédentes ont caractérisé, condition par condition, les mondes lexicaux internes à chaque sous-corpus. L'analyse factorielle des correspondances (AFC) vise un objectif complémentaire : projeter dans un même espace géométrique les journaux et les catégories discursives, afin de visualiser leurs proximités et leurs oppositions de façon synthétique. Là où les dendrogrammes décrivent la structure lexicale, l'AFC cartographie les positionnements relatifs des titres.

Trois tableaux de contingence sont successivement soumis à l'analyse. Le premier (AFC B) croise les sept journaux et les quatre conditions discursives : il fournit la vue d'ensemble la plus directe pour examiner si les titres se distribuent selon un axe opposant les registres « génocide » et « terrorisme », et constitue à ce titre la figure de synthèse de l'hypothèse d'autonomie des deux champs. Le deuxième (AFC A) croise, au sein de chaque condition, les journaux et les mondes lexicaux issus de la CHD : il permet d'observer quels titres portent quels registres. Le troisième (AFC D) réunit l'ensemble des classes de toutes les conditions dans un espace unique, offrant la cartographie la plus complète, au prix d'une lecture plus exigeante.

L'interprétation suit les conventions de l'analyse géométrique des données : la proximité entre deux modalités traduit une similarité de profil, l'inertie portée par chaque axe indique sa part dans la structuration du nuage, et les contributions identifient les modalités qui déterminent chaque dimension. Le pourcentage d'inertie restitué par les deux premiers axes conditionne la robustesse de la lecture plane et sera donc précisé pour chaque analyse.

```
library(FactoMineR)
library(factoextra)
library(tibble)

corpus_genocide <- resultats[["génocide seul"]]$corpus |> mutate(cluster_label = paste0("G", 1:nrow(corpus_genocide)))
corpus_terrorisme <- resultats[["terrorisme seul"]]$corpus |> mutate(cluster_label = paste0("T", 1:nrow(corpus_terrorisme)))
corpus_geno_terre <- resultats[["génocide + terrorisme"]]$corpus |> mutate(cluster_label = paste0("G", 1:nrow(corpus_geno_terre)))
corpus_sans <- resultats[["ni génocide ni terrorisme"]]$corpus |> mutate(cluster_label = paste0("S", 1:nrow(corpus_sans)))
```


13.1 AFC B — Journaux × Conditions (figure de synthèse)

```
tab_B <- bind_rows(corpus_genocide, corpus_terrorisme,
                  corpus_geno_terre, corpus_sans) |>
  mutate(journal = factor(journal, levels = ordre_journaux)) |>
  group_by(journal, condition) |>
  summarise(n = n(), .groups = "drop") |>
  pivot_wider(names_from = condition, values_from = n, values_fill = 0) |>
  column_to_rownames("journal")

afc_B <- CA(tab_B, graph = FALSE)
print(afc_B$eig)

##          eigenvalue percentage of variance cumulative percentage of variance
## dim 1 0.071901720          73.601619          73.60162
## dim 2 0.023441416          23.995617          97.59724
## dim 3 0.002347269           2.402763          100.00000

fviz_ca_biplot(afc_B, repel = TRUE, col.row = "#2c3e50",
               col.col = c("#c0392b", "#e67e22", "#2980b9", "#7f8c8d"),
               title = "AFC B - Journaux × Conditions discursives") +
  theme_minimal(base_size = 12) +
  theme(plot.title = element_text(face = "bold")) +
  theme(legend.position = "none")
```




COMMENTAIRE FIGURE A VENIR PLUS TARD.

13.2 AFC A — Journaux × Clusters, par condition

```
library(patchwork)

faire_afc_A <- function(corpus_cond, condition_cible, couleur) {
  tab <- corpus_cond |>
    mutate(journal = factor(journal, levels = ordre_journaux)) |>
    group_by(journal, cluster) |>
    summarise(n = n(), .groups = "drop") |>
    pivot_wider(names_from = cluster, values_from = n,
                values_fill = 0, names_prefix = "Cluster_") |>
    column_to_rownames("journal")
  afc <- CA(tab, graph = FALSE)
  fviz_ca_biplot(afc, repel = TRUE, col.row = "#2c3e50", col.col = couleur,
                 title = paste0("AFC A - '", condition_cible, "'") +
                 theme_minimal(base_size = 11) +
                 theme(plot.title = element_text(face = "bold", size = 11))
}
```

```
(faire_afc_A(corpus_genocide, "génocide seul", "#e67e22") +
 faire_afc_A(corpus_terrorisme, "terrorisme seul", "#2980b9")) /
(faire_afc_A(corpus_genos_terre, "génocide + terrorisme", "#c0392b") +
 faire_afc_A(corpus_sans, "ni génocide ni terrorisme", "#7f8c8d"))
```



COMMENTAIRE FIGURE A VENIR PLUS TARD.

13.3 AFC D — Journaux × tous les clusters

```
tab_D <- bind_rows(corpus_genocide, corpus_terrorisme,
                   corpus_genos_terre, corpus_sans) |>
  mutate(journal = factor(journal, levels = ordre_journaux)) |>
  group_by(journal, cluster_label) |>
  summarise(n = n(), .groups = "drop") |>
  pivot_wider(names_from = cluster_label, values_from = n, values_fill = 0) |>
  column_to_rownames("journal")

afc_D <- CA(tab_D, graph = FALSE)
```

```
print(afc_D$eig)
```


```
##          eigenvalue percentage of variance cumulative percentage of variance
## dim 1 0.105420060          51.93607          51.93607
## dim 2 0.060424701          29.768730         81.70480
## dim 3 0.020104770           9.904782         91.60958
## dim 4 0.009317087           4.590140         96.19972
## dim 5 0.006301582           3.104526         99.30425
```

```
couleurs_D <- case_when(
  str_starts(colnames(tab_D), "G_") ~ "#e67e22",
  str_starts(colnames(tab_D), "T_") ~ "#2980b9",
  str_starts(colnames(tab_D), "GT_") ~ "#c0392b",
  str_starts(colnames(tab_D), "S_") ~ "#7f8c8d"
)
```

```
fviz_ca_biplot(afc_D, repel = TRUE, col.row = "#2c3e50", col.col = couleurs_D,
  title = "AFC D - Journaux x Clusters (toutes conditions)" +
  theme_minimal(base_size = 11) +
  theme(plot.title = element_text(face = "bold")) +
  theme(legend.position = "none")
```



```
(fviz_contrib(afc_D, choice = "row", axes = 1:2, top = 10) +
  labs(title = "Journaux contributifs (axes 1+2)") + theme_minimal(base_size = 11)) +
(fviz_contrib(afc_D, choice = "col", axes = 1:2, top = 15) +
  labs(title = "Clusters contributifs (axes 1+2)") + theme_minimal(base_size = 11))
```



COMMENTAIRE FIGURE A VENIR PLUS TARD.

14 Marqueur de rupture temporelle : “désormais”

Au-delà de la composition lexicale des sous-corpus, l’analyse du cadrage gagne à s’intéresser aux marques linguistiques par lesquelles les discours construisent leur propre temporalité. Chateauraynaud et Doury (2010) ont montré que l’adverbe “désormais” constitue, à cet égard, un indicateur particulièrement révélateur. Loin d’être un simple repère chronologique, il opère une rupture temporelle : il découpe un avant et un après, et présente la période qu’il ouvre comme durable, voire irréversible. Son emploi suppose généralement un attracteur temporel — un événement, une décision, une épreuve — donné comme point de bascule à partir duquel l’état du monde est requalifié.

Les auteurs distinguent plusieurs régimes de cette rupture, qui éclairent directement notre objet. “Désormais” peut introduire une rupture épistémique (un nouvel état des savoirs présenté comme acquis et soustrait à la discussion), une rupture déontique (l’instauration de nouvelles normes ou obligations, souvent à la suite d’une décision juridique ou politique), ou encore l’ouverture d’un nouveau champ des possibles (par exemple à la faveur de l’arrivée d’une nouvelle technologie supposée révolutionnaire). Dans tous les cas, l’adverbe possède une dimension argumentative, voire performative : en énonçant la rupture, il contribue à la faire advenir, et signale les moments où les acteurs prétendent réorganiser la périodisation d’un débat.

Cet outil est précieux pour notre analyse à un double titre. D’une part, la fréquence et la distribution de “désormais” dans les différents sous-corpus permettent de repérer quel registre discursif mobilise le plus volontiers la rhétorique de la rupture. D’autre part, ses pics temporels signalent les moments où la presse construit discursivement un point de bascule, que l’on peut alors rapporter aux événements précis du conflit sur la séquence étudiée. L’adverbe offre ainsi une entrée fine, à l’échelle de la phrase, pour observer comment les titres périodisent les événements et transforment certains d’entre eux en seuils argumentatifs.

14.1 Fréquence par condition

```
desormais <- lemmes_raw |>
  mutate(token_lower = tolower(token)) |>
  filter(token_lower == "désormais") |>
  left_join(corpus |> select(nodoc, condition, journal),
    by = c("doc_id" = "nodoc")) |>
  filter(!is.na(condition))

total_lemmes <- lemmes_raw |>
  left_join(corpus |> select(nodoc, condition), by = c("doc_id" = "nodoc")) |>
  filter(!is.na(condition)) |>
  group_by(condition) |>
  summarise(n_lemmes = n(), .groups = "drop")

n_docs_condition <- corpus |> count(condition, name = "n_docs_total")

desormais_stats <- desormais |>
  group_by(condition) |>
  summarise(n_occurrences = n(), n_docs = n_distinct(doc_id), .groups = "drop") |>
  left_join(total_lemmes, by = "condition") |>
  left_join(n_docs_condition, by = "condition") |>
  mutate(freq_pour_mille = round(n_occurrences / n_lemmes * 1000, 3),
    pct_docs = round(n_docs / n_docs_total * 100, 1))

desormais_stats
```

```
## # A tibble: 4 x 7
##   condition  n_occurrences n_docs n_lemmes n_docs_total freq_pour_mille pct_docs
##   <fct>          <int>   <int>   <int>         <int>         <dbl>    <dbl>
## 1 génocide ~         203     144   785987         517         0.258    27.9
## 2 génocide ~         312     222  1047181         891         0.298    24.9
## 3 terrorism~        1345     986  4284252        3516         0.314     28
## 4 ni génoci~        1680    1272  5656487        5928         0.297    21.5
```

COMMENTAIRE FIGURE A VENIR PLUS TARD.

14.2 Série temporelle de “désormais”

```
desormais_temps <- desormais |>
  left_join(corpus |> select(nodoc, annee_mois), by = c("doc_id" = "nodoc")) |>
  filter(!is.na(annee_mois)) |>
  group_by(annee_mois, condition) |>
  summarise(n = n(), .groups = "drop") |>
  complete(annee_mois, condition, fill = list(n = 0))

total_lemmes_mois <- lemmes_raw |>
  left_join(corpus |> select(nodoc, condition, annee_mois),
    by = c("doc_id" = "nodoc")) |>
  filter(!is.na(condition)) |>
  group_by(annee_mois, condition) |>
  summarise(n_lemmes = n(), .groups = "drop")


desormais_temps <- desormais_temps |>
```

```

left_join(total_lemmes_mois, by = c("annee_mois", "condition")) |>
mutate(freq_pour_mille = if_else(n_lemmes > 0, n / n_lemmes * 1000, 0))

ggplot(desormais_temps, aes(x = annee_mois, y = freq_pour_mille, color = condition)) +
  geom_line(linewidth = 0.9) + geom_point(size = 1.5, alpha = 0.7) +
  scale_color_manual(values = palette_conditions) +
  scale_x_date(date_labels = "%b %Y", date_breaks = "2 months") +
  labs(title = "Fréquence mensuelle de 'désormais' par condition discursive",
       subtitle = "Occurrences pour 1000 lemmes", x = NULL, y = "Fréquence (%)",
       color = NULL) +
  theme_minimal(base_size = 11) +
  theme(axis.text.x = element_text(angle = 45, hjust = 1),
        plot.title = element_text(face = "bold"), legend.position = "bottom")

```



COMMENTAIRE FIGURE A VENIR PLUS TARD.

14.3 Réseau de cooccurrences de “désormais”

```

library(ggraph)
library(igraph)
library(tidygraph)

fcm_desormais <- fcm(toks, context = "window", window = 5,
                    count = "frequency", tri = TRUE)

if ("désormais" %in% featnames(fcm_desormais)) {
  cooc <- fcm_desormais["désormais", ] |>
  as.matrix() |> t() |> as.data.frame() |>
  tibble::rownames_to_column("mot") |>
  rename(cooc = V1) |>
  filter(mot != "désormais", cooc > 0) |>
  slice_max(cooc, n = 40)

  edges <- cooc |> mutate(from = "désormais", to = mot, weight = cooc) |>
  select(from, to, weight)
}

```

```

g <- graph_from_data_frame(edges, directed = FALSE) |>
  as_tbl_graph() |>
  mutate(centralite = centrality_degree(weights = weight),
         est_pivot = name == "désormais")

ggraph(g, layout = "fr") +
  geom_edge_link(aes(width = weight, alpha = weight),
                 color = "#95a5a6", show.legend = FALSE) +
  geom_node_point(aes(size = centralite, color = est_pivot), show.legend = FALSE) +
  geom_node_label(aes(label = name), repel = TRUE,
                  label.padding = unit(0.15, "lines"), label.size = 0.2) +
  scale_color_manual(values = c("TRUE" = "#e74c3c", "FALSE" = "#2c3e50")) +
  scale_edge_width(range = c(0.3, 2.5)) +
  scale_edge_alpha(range = c(0.2, 0.8)) +
  scale_size(range = c(3, 8)) +
  labs(title = "Réseau de cooccurrences de 'désormais'",
       subtitle = "Fenêtre de 5 tokens | Top 40 cooccurrents") +
  theme_graph(base_size = 11) +
  theme(plot.title = element_text(face = "bold"))
} else {
  cat("'désormais' absent des featnames - vérifier la tokenisation\n")
}

```

'désormais' absent des featnames - vérifier la tokenisation

COMMENTAIRE FIGURE A VENIR PLUS TARD.

14.4 Étude de cas : Le Figaro et la “guerre des 12 jours” (juin 2025)

COMMENTAIRE FIGURE A VENIR PLUS TARD.

```

figaro_juin25 <- corpus |>
  filter(journal == "Figaro", condition == "terrorisme seul",
         annee_mois == as.Date("2025-06-01")) |>
  left_join(resultats[["terrorisme seul"]]$assignation, by = "nodoc") |>
  mutate(periode = case_when(
    date >= as.Date("2025-06-13") & date <= as.Date("2025-06-24") ~ "guerre 12 jours",
    date < as.Date("2025-06-13") ~ "avant",
    date > as.Date("2025-06-24") ~ "après"
  ))

```

Distribution des clusters par période

```

figaro_juin25 |>
  group_by(periode, cluster) |>
  summarise(n = n(), .groups = "drop") |>
  group_by(periode) |>
  mutate(pct = round(n / sum(n) * 100, 1)) |>
  arrange(periode, desc(n))

```

```

## # A tibble: 10 x 4
## # Groups:   periode [3]
##   periode      cluster      n  pct
##   <chr>         <int> <int> <dbl>
## 1 après          4      4  80
## 2 après          2      1  20

```



```
## 3 avant 3 4 50
## 4 avant 2 2 25
## 5 avant 5 2 25
## 6 guerre 12 jours 4 13 56.5
## 7 guerre 12 jours 3 4 17.4
## 8 guerre 12 jours 1 3 13
## 9 guerre 12 jours 2 2 8.7
## 10 guerre 12 jours 5 1 4.3

# Concentration temporelle des occurrences de "désormais"
desormais |>
  left_join(corpus |> select(nodoc, date, annee_mois),
            by = c("doc_id" = "nodoc")) |>
  filter(journal == "Figaro", condition == "terrorisme seul",
         annee_mois == as.Date("2025-06-01")) |>
  mutate(periode = case_when(
    date >= as.Date("2025-06-13") & date <= as.Date("2025-06-24") ~ "guerre 12 jours",
    date < as.Date("2025-06-13") ~ "avant",
    date > as.Date("2025-06-24") ~ "après"
  )) |>
  count(periode) |>
  mutate(pct = round(n / sum(n) * 100, 1))

##      periode  n  pct
## 1      après  8 25.0
## 2      avant  6 18.8
## 3 guerre 12 jours 18 56.2
```

COMMENTAIRE FIGURE A VENIR PLUS TARD.

15 Conclusion

A VENIR PLUS TARD.

16 Références provisoires

A COMPLETER PLUS TARD.

Duval Julien, «Matérialismes, culture & communication» dans Matérialismes, culture & communication, s.l., Les Presses des Mines, 2016, p.405-422.

El Damanhoury Kareem, Saleh Faisal et Lebovic Madeleine, «Covering the Israeli–Palestinian Conflict : A Critical Discourse Analysis of Al Jazeera English and BBC’s Online Reporting on the 2023 Gaza War», Journalism and Media, 16 janvier 2025, vol.6, n 1, p. 9.

Entman Robert M., «Framing : Toward Clarification of a Fractured Paradigm», Journal of Communication, 1 décembre 1993, vol.43, n 4, p. 51-58.

Handley Robert L., «THE CONFLICTING ISRAELI-TERRORIST IMAGE : Managing the Israeli–Palestinian narrative in the New York Times and Washington Post», Journalism Practice, août 2009, vol.3, n 3, p. 251-267.

Kent Gregory et Palmer Jerry, «Le conflit Israélo-Palestinien : médias occidentaux, «revendications de vérité» et antisémitisme», Questions de communication, 2007, vol.11, p. 205-218.

Kozman Claudia et Cozma Raluca, «War and peace journalism in the 2023 Israel–Gaza war : A comparative analysis of the headlines of five international news agencies», International Communication Gazette, juin

2026, vol.88, n 4, p. 367-386.

Lefébure Alessia, Quand le conflit israélo-palestinien déborde sur les campus américains, <https://theconversation.com/quand-le-conflit-israelo-palestinien-deborde-sur-les-campus-americains-217836> , 20 novembre 2023, consulté le 28 juin 2026.

Max Reinert, «Les “mondes lexicaux” et leur ‘logique’ à travers l’analyse statistique d’un corpus de récits de cauchemars», *Langage et société*, 1993, vol.66, n 1, p. 5-39. Van Dijk Teun A., «Principles of Critical Discourse Analysis», *Discourse & Society*, avril 1993, vol.4, n 2, p. 249-283.

17 Annexe : informations de session

`sessionInfo()`

```
## R version 4.3.3 (2024-02-29)
## Platform: x86_64-pc-linux-gnu (64-bit)
## Running under: Ubuntu 24.04.4 LTS
##
## Matrix products: default
## BLAS: /usr/lib/x86_64-linux-gnu/blas/libblas.so.3.12.0
## LAPACK: /usr/lib/x86_64-linux-gnu/lapack/liblapack.so.3.12.0
##
## locale:
##  [1] LC_CTYPE=fr_FR.UTF-8      LC_NUMERIC=C
##  [3] LC_TIME=fr_FR.UTF-8      LC_COLLATE=fr_FR.UTF-8
##  [5] LC_MONETARY=fr_FR.UTF-8  LC_MESSAGES=fr_FR.UTF-8
##  [7] LC_PAPER=fr_FR.UTF-8     LC_NAME=C
##  [9] LC_ADDRESS=C             LC_TELEPHONE=C
## [11] LC_MEASUREMENT=fr_FR.UTF-8 LC_IDENTIFICATION=C
##
## time zone: Europe/Paris
## tzcode source: system (glibc)
##
## attached base packages:
## [1] stats      graphics  grDevices  utils      datasets  methods   base
##
## other attached packages:
##  [1] tidygraph_1.3.1          igraph_2.3.2
##  [3] ggraph_2.2.2             tibble_3.3.1
##  [5] factoextra_2.0.0         FactoMineR_2.15
##  [7] rainette_0.3.3           quanteda.textplots_0.96.1
##  [9] quanteda.textstats_0.97.2 quanteda_4.4
## [11] janitor_2.2.1            patchwork_1.3.2
## [13] zoo_1.8-15              tidyr_1.3.2
## [15] ggplot2_4.0.3            purrr_1.2.2
## [17] stringr_1.6.0           lubridate_1.9.5
## [19] dplyr_1.2.1             rvest_1.0.5
##
## loaded via a namespace (and not attached):
##  [1] gridExtra_2.3            rlang_1.2.0             magrittr_2.0.5
##  [4] snakecase_0.11.1        otel_0.2.0              compiler_4.3.3
##  [7] png_0.1-9              vctr_0.7.3              pkgconfig_2.0.3
## [10] crayon_1.5.3            fastmap_1.2.0           backports_1.5.1
## [13] labeling_0.4.3          utf8_1.2.6              promises_1.5.0
```

## [16] rmarkdown_2.31	tzdb_0.5.0	bit_4.6.0
## [19] xfun_0.59	cachem_1.1.0	flashClust_1.1-4
## [22] later_1.4.8	tweenr_2.0.3	broom_1.0.13
## [25] parallel_4.3.3	irlba_2.3.7	stopwords_2.3
## [28] cluster_2.1.8.2	R6_2.6.1	stringi_1.8.7
## [31] RColorBrewer_1.1-3	car_3.1-5	estimability_1.5.1
## [34] nsyllable_1.0.1	Rcpp_1.1.1-1.1	knitr_1.51
## [37] readr_2.2.0	httpuv_1.6.17	Matrix_1.6-5
## [40] timechange_0.4.0	tidyselect_1.2.1	abind_1.4-8
## [43] yaml_2.3.12	viridis_0.6.5	miniUI_0.1.2
## [46] ggwordcloud_0.6.2	lattice_0.22-5	shiny_1.14.0
## [49] withr_3.0.3	S7_0.2.2	coda_0.19-4.1
## [52] evaluate_1.0.5	polyclip_1.10-7	xml2_1.6.0
## [55] ggpubr_0.6.3	pillar_1.11.1	carData_3.0-6
## [58] DT_0.34.0	generics_0.1.4	vroom_1.7.1
## [61] hms_1.1.4	scales_1.4.0	xtable_1.8-8
## [64] leaps_3.2	glue_1.8.1	emmeans_2.0.3
## [67] scatterplot3d_0.3-45	tools_4.3.3	dendextend_1.19.1
## [70] RSpectra_0.16-2	ggsignif_0.6.4	mvtnorm_1.4-1
## [73] graphlayouts_1.2.4	fastmatch_1.1-8	grid_4.3.3
## [76] colorspace_2.1-2	ggforce_0.5.0	Formula_1.2-5
## [79] cli_3.6.6	viridisLite_0.4.3	gtable_0.3.6
## [82] rstatix_0.7.3	selectr_0.6-0	digest_0.6.39
## [85] progressr_0.19.0	ggrepel_0.9.8	htmlwidgets_1.6.4
## [88] farver_2.1.2	memoise_2.0.1	htmltools_0.5.9
## [91] lifecycle_1.0.5	httr_1.4.8	multcompView_0.1-11
## [94] mime_0.13	gridtext_0.1.6	bit64_4.8.2
## [97] MASS_7.3-60.0.1		