

TP Séries temporelles appliquées

Modèle ARMA(p,q) et méthode des moindres carrés ordinaires

Brice Rauby, Ilyas Hanine

3 mars 2020

Contents

PARTIE 1 : Estimation du modèle	2
Importation et traitement des données	2
Tracé de la série temporelle	3
Question 2	4
Question 3	4
Question 4 — Régression linéaire	5
Question 5 — Étude des résidus	5
Question 6 — Séparation du jeu de données	8
PARTIE 2 : Estimation d'une nouvelle spécification et comparaison	17
Modèle corrigé sur l'ensemble de la période	17
Modèle corrigé avant 2002	21
Modèle corrigé après 2002	25
PARTIE 3 : Modèle ARMA(p,q)	29
Question 8 — Le modèle ARMA(p,q)	29
Question 9 — Ordre du modèle	29
Question 10 — Estimation du modèle	30
Question 11 — Prévission et intervalle de confiance à 95 %	30
Question 12 — Comparaison RMSE / MAE	34
Question 11 bis — Test de Diebold-Mariano	35
PARTIE 4 : Stabilité du modèle	35
Question 13 — Estimation glissante	35
Question 14 — Test CUSUM	36

```
library(ggplot2)      # graphiques
library(stringr)      # traitement des chaînes (str_replace_all)
library(lubridate)    # parsing des dates (parse_date_time2)
library(forecast)     # auto.arima, forecast, dm.test
library(strucchange)  # test CUSUM (efp)

# Fonction réutilisable d'étude des résidus d'un modèle linéaire :
# résumé, normalité (histogramme + densité, QQ-plot, test de Kolmogorov-Smirnov),
# autocorrélation (ACF) et hétéroscédasticité.
diagnostics_residus <- function(modele, titre = "") {
  res <- residuals(modele)
  fit <- fitted(modele)

  print(summary(res))
```

```

# Normalité : histogramme et densité
hist(res, freq = FALSE, col = "lightblue",
      main = paste("Densité des résidus", titre), xlab = "Résidus")
lines(density(res), col = "blue", lwd = 2)

# Normalité : QQ-plot des résidus standardisés
stand_res <- (res - mean(res)) / sd(res)
qqnorm(stand_res, main = paste("QQ-plot", titre)); qqline(stand_res)

# Normalité : test de Kolmogorov-Smirnov
print(ks.test(res, "pnorm", mean = mean(res), sd = sd(res)))

# Autocorrélation
acf(res, main = paste("ACF des résidus", titre))

# Hétéroscédasticité : |résidus| en fonction des valeurs ajustées
plot(abs(res) ~ fit, xlab = "Valeurs ajustées", ylab = "|Résidus|",
      main = paste("Hétéroscédasticité", titre))
abline(lm(abs(res) ~ fit), col = "red")
}

```

PARTIE 1 : Estimation du modèle

Le modèle économétrique que nous allons mettre en œuvre est le suivant (avec les notations de l'énoncé) :

$$\frac{E_t}{P_t} = \alpha + \beta \cdot r_t + \epsilon_t$$

où $\epsilon_t \sim \mathcal{N}(0, \sigma_\epsilon^2)$.

Importation et traitement des données

```

data <- read.csv("data.csv", sep = ";", header = TRUE)[1:711, 1:6]

# Earning yield = bénéfices / prix
data[["earning yield"]] <- data[["earnings"]] / data[["price"]]

# Conversion de la colonne de dates ("janv-60", "févr-60", ...) en objet Date
months      <- c("janv", "fevr", "mars", "avr", "mai", "juin",
                 "juil", "aout", "sept", "oct", "nov", "dec")
months_num  <- c("01", "02", "03", "04", "05", "06",
                 "07", "08", "09", "10", "11", "12")


data$X <- iconv(data$X, from = "UTF-8", to = "ASCII//TRANSLIT") # févr->fevr, août->aout, déc->dec
data$X <- str_replace_all(data$X, setNames(months_num, months)) # remplacement par dictionnaire
data$X <- as.Date(parse_date_time2(data$X, "my", cutoff_2000 = 20L))
names(data)[names(data) == "X"] <- "date"

# Taux réel = taux nominal - inflation sur 12 mois (cpi_t - cpi_{t-12}).
# Calculé une seule fois sur l'ensemble de la période (utilisé en Partie 2).
infl12 <- c(rep(NA_real_, 12), diff(data$cpi, lag = 12))
data$real_rates <- data$rates - infl12
data$real_rates[1:12] <- data$rates[1:12] # pas d'historique sur la première année


```

Tracé de la série temporelle

```
ggplot(data, aes(date, `earning yield`)) +  
  geom_line(color = "red", size = 1) +  
  ylab("Earning yield indice S&P500")
```



```
# geom_smooth ajuste directement la droite de régression aux données.  
# La régression linéaire semble raisonnable.  
ggplot(data, aes(x = rates, y = `earning yield`)) +  
  geom_point(size = 1, color = "blue") +  
  geom_smooth(method = "lm", se = TRUE, color = "red")
```



La figure justifie l'intuition d'un modèle linéaire. Mettons-le maintenant en œuvre.

Question 2

Le principe de l'estimateur des moindres carrés est de réaliser une régression linéaire au sens de la norme L_2 . Soit un ensemble d'observations $(X_i, Y_i)_{i \in [1, n]}$ (vectorielles ou scalaires) ; on dit que X est la variable explicative. L'estimateur des moindres carrés est donné par $\hat{\alpha}$ et $\hat{\beta}$ minimisant $\sum_{i=1}^n \|Y_i - (\beta X_i + \alpha)\|^2$. Autrement dit, la méthode des moindres carrés ordinaires consiste à trouver la droite qui minimise le carré de l'erreur sur l'ensemble des observations. Les hypothèses sous-jacentes sont qu'il existe une corrélation entre X et Y et que les valeurs prises par la variable explicative sont exactes.

Question 3

Puisque l'on cherche à minimiser :

$$L(\alpha, \beta) := \sum_{i=1}^n \|Y_i - (\beta X_i + \alpha)\|^2$$

Dans notre cas $(X_i, Y_i) \in \mathbf{R}$. On note $L_i := \|Y_i - (\beta X_i + \alpha)\|^2$. La fonction étant convexe et coercive, on conclut à l'existence et l'unicité du minimum dans $\mathbf{R}^2$. On annule le gradient ; il vient :

$$\frac{\partial}{\partial \alpha} L_i = \frac{\partial}{\partial \alpha} (Y_i - (\beta X_i + \alpha))^2 = -2(Y_i - (\beta X_i + \alpha))$$

$$\frac{\partial}{\partial \alpha} L = 0 \iff \sum_{i=1}^n (Y_i - (\beta X_i + \alpha)) = 0$$

$$\frac{\partial}{\partial \alpha} L = 0 \iff \sum_{i=1}^n (Y_i - \beta X_i) = n\alpha$$

Ceci étant vrai pour tout β reste vrai pour $\hat{\beta}$; en remplaçant X_i et Y_i par r_t et $\frac{E_t}{P_t}$ et en prenant les moyennes empiriques :

$$\hat{\alpha} = \frac{1}{n} \sum_{i=1}^n (Y_i - \hat{\beta} X_i) = \overline{\left(\frac{E}{P}\right)} - \hat{\beta} \bar{r}$$

De même, en dérivant par rapport à β :

$$\frac{\partial}{\partial \beta} L_i = \frac{\partial}{\partial \beta} (Y_i - (\beta X_i + \alpha))^2 = -2X_i(Y_i - (\beta X_i + \alpha))$$

En remplaçant comme précédemment et en se plaçant en $\hat{\alpha}$:

$$\sum_{t=1}^n r_t \left(\frac{E_t}{P_t} - \overline{\left(\frac{E}{P}\right)} - \hat{\beta}(r_t - \bar{r}) \right) = 0$$

ce qui revient à :

$$\sum_{t=1}^n r_t \frac{E_t}{P_t} - \overline{\left(\frac{E}{P}\right)} \sum_{t=1}^n r_t = \hat{\beta} \left(\sum_{t=1}^n r_t^2 - \bar{r} \sum_{t=1}^n r_t \right)$$

En remplaçant par la variance et la covariance appropriées, on obtient le résultat demandé :

$$\hat{\beta} = \frac{\text{Cov}\left(\frac{E}{P}, r\right)}{\sigma_r^2}$$

Question 4 — Régression linéaire



```
modele <- lm(`earning yield` ~ rates, data)
summary(modele)

##
## Call:
## lm(formula = `earning yield` ~ rates, data = data)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.039533 -0.012084 -0.000824  0.009177  0.060914
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  0.0235860   0.0016389   14.39  <2e-16 ***
## rates        0.0064668   0.0002438   26.52  <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.01875 on 709 degrees of freedom
## Multiple R-squared:  0.4981, Adjusted R-squared:  0.4974
## F-statistic: 703.6 on 1 and 709 DF, p-value: < 2.2e-16
```


Question 5 — Étude des résidus

```
diagnostics_residus(modele)
```


##	Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
##	-0.0395333	-0.0120844	-0.0008244	0.0000000	0.0091769	0.0609139



```
##
## Asymptotic one-sample Kolmogorov-Smirnov test
##
## data:  res
## D = 0.075955, p-value = 0.0005472
## alternative hypothesis: two-sided
```



Hétéroscédasticité



Normalité. L'histogramme et le QQ-plot permettent raisonnablement de conclure à la normalité des résidus, sans que les conclusions soient parfaites.

Autocorrélation. Les résidus apparaissent très fortement corrélés au vu de l'ACF : il existe une relation linéaire marquée entre résidus successifs.

Hétéroscédasticité. L'homoscédasticité signifierait l'absence de relation entre la dispersion des résidus et les valeurs ajustées. Ce n'est pas tout à fait vérifié : la droite rouge tend à croître avec les valeurs ajustées. En présence d'hétéroscédasticité, on privilégierait les moindres carrés **généralisés** (GLS) ou pondérés (WLS), ou des écarts-types robustes (White).


Question 6 — Séparation du jeu de données

On découpe le jeu de données en deux parties : de 1961 à décembre 2001, puis de janvier 2002 à mars 2019, et l'on déroule la même analyse.

```
data_before <- data[data$date < as.Date("2002-01-01"), ]
data_after  <- data[data$date >= as.Date("2002-01-01"), ]


ggplot(data_before, aes(x = rates, y = `earning yield`)) +
  geom_point(size = 1, color = "blue") +
  geom_smooth(method = "lm", se = TRUE, color = "red") + ggtitle("Avant 2002")
```

Avant 2002



```
ggplot(data_after, aes(x = rates, y = `earning yield`)) +  
  geom_point(size = 1, color = "blue") +  
  geom_smooth(method = "lm", se = TRUE, color = "red") + ggtitle("Après 2002")
```

Après 2002



Ce qui change surtout, c'est qu'après 2002 le taux ne porte plus d'information : le coefficient β devient non significatif (t-value faible). Par ailleurs, les résidus ne sont plus corrélés au-delà d'un certain rang et l'on retrouve de l'hétéroscédasticité.

MCO avant 2002


```
modele.before <- lm(`earning yield` ~ rates, data_before)
summary(modele.before)

##
## Call:
## lm(formula = `earning yield` ~ rates, data = data_before)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.034234 -0.013497 -0.003599  0.010624  0.062521
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  0.0091457  0.0030719   2.977  0.0031 **
## rates        0.0081940  0.0003992  20.528 <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.01949 on 376 degrees of freedom
## (178 observations effacées parce que manquantes)
```


```
## Multiple R-squared:  0.5285, Adjusted R-squared:  0.5272
## F-statistic: 421.4 on 1 and 376 DF,  p-value: < 2.2e-16
```

```
diagnostics_residus(modele.before, "(avant 2002)")
```

```
##      Min.    1st Qu.    Median      Mean   3rd Qu.      Max.
## -0.034234 -0.013497 -0.003599  0.000000  0.010624  0.062521
```




QQ-plot (avant 2002)




```
##  
## Asymptotic one-sample Kolmogorov-Smirnov test  
##  
## data: res  
## D = 0.089525, p-value = 0.004673  
## alternative hypothesis: two-sided
```

ACF des résidus (avant 2002)



Hétéroscédasticité (avant 2002)



MCO après 2002


```
modele.after <- lm(`earning yield` ~ rates, data_after)
summary(modele.after)

##
## Call:
## lm(formula = `earning yield` ~ rates, data = data_after)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.040076 -0.005738  0.000319  0.008098  0.024068
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  0.0488415   0.0032347   15.10  <2e-16 ***
## rates       -0.0001764   0.0009810   -0.18   0.858
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.01245 on 153 degrees of freedom
## (178 observations effacées parce que manquantes)
## Multiple R-squared:  0.0002113, Adjusted R-squared:  -0.006323
## F-statistic: 0.03233 on 1 and 153 DF,  p-value: 0.8575


diagnostics_residus(modele.after, "(après 2002)")

##      Min.      1st Qu.      Median      Mean      3rd Qu.      Max.
## -0.0400762 -0.0057380  0.0003189  0.0000000  0.0080978  0.0240685
```

Densité des résidus (après 2002)




QQ-plot (après 2002)




```
##
##  Asymptotic one-sample Kolmogorov-Smirnov test
##
## data:  res
## D = 0.11736, p-value = 0.02796
## alternative hypothesis: two-sided
```

ACF des résidus (après 2002)



Hétéroscédasticité (après 2002)



Il existe des familles de modèles capables de prendre en charge ce type de configuration (rupture de structure) : modèles à changement de régime (Markov-switching), modèles à seuil (TAR/SETAR), ou estimation par sous-périodes après détection de la date de rupture.

PARTIE 2 : Estimation d'une nouvelle spécification et comparaison

Le modèle est ici corrigé de l'évolution du CPI sur l'année courante :

$$\frac{E_t}{P_t} = \alpha' + \beta' \cdot (r_t - \pi_{\text{année}}) + \epsilon_t$$

En appliquant les MCO, on espère ainsi faire apparaître un taux réel r'_t :

$$\frac{E_t}{P_t} = \alpha' + \beta' \cdot rr_t + \epsilon_t = \alpha' + \beta' \cdot r'_t + \epsilon_t$$


Le taux réel a été calculé une fois pour toutes dans le chunk d'import (`real_rates = rates - (cpi_t - cpi_{t-12})`) ; les sous-jeux `data_before` et `data_after` en héritent automatiquement.

Modèle corrigé sur l'ensemble de la période

```
modele.mci <- lm(`earning yield` ~ real_rates, data)
summary(modele.mci)

##
## Call:
## lm(formula = `earning yield` ~ real_rates, data = data)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.071115 -0.014852 -0.004702  0.007747  0.088073
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) 0.0559340   0.0011523   48.54  <2e-16 ***
## real_rates   0.0030602   0.0003022   10.13  <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.02474 on 709 degrees of freedom
## Multiple R-squared:  0.1264, Adjusted R-squared:  0.1251
## F-statistic: 102.6 on 1 and 709 DF, p-value: < 2.2e-16

ggplot(data, aes(x = real_rates, y = `earning yield`)) +
  geom_point(size = 1, color = "blue") +
  geom_smooth(method = "lm", se = TRUE, color = "red")
```




Le coefficient de détermination (de l'ordre de 12 %, inférieur à celui du modèle nominal) montre que la régression globale est moins ajustée. L'étude des résidus le confirme.


```
diagnostics_residus(modele.mci, "(modèle corrigé, global)")
```

```
##      Min.   1st Qu.   Median     Mean   3rd Qu.     Max.
## -0.071115 -0.014852 -0.004702  0.000000  0.007747  0.088073
```

Densité des résidus (modèle corrigé, global)




QQ-plot (modèle corrigé, global)




```
##  
## Asymptotic one-sample Kolmogorov-Smirnov test  
##
```

```
## data: res
## D = 0.13649, p-value = 6.254e-12
## alternative hypothesis: two-sided
```

ACF des résidus (modèle corrigé, global)



Hétéroscédasticité (modèle corrigé, global)



L'étude des résidus confirme que le modèle corrigé n'est pas adapté sur l'ensemble de la période. Appliquons-le aux deux sous-périodes.


Modèle corrigé avant 2002

```
modele.mci.before <- lm(`earning yield` ~ real_rates, data_before)
summary(modele.mci.before)

##
## Call:
## lm(formula = `earning yield` ~ real_rates, data = data_before)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.04364 -0.01667 -0.01028  0.01102  0.09189
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) 0.0500158  0.0031203  16.029  < 2e-16 ***
## real_rates  0.0050242  0.0007504   6.695 7.86e-11 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.02683 on 376 degrees of freedom
## (178 observations effacées parce que manquantes)
## Multiple R-squared:  0.1065, Adjusted R-squared:  0.1041
## F-statistic: 44.82 on 1 and 376 DF,  p-value: 7.864e-11

ggplot(data_before, aes(x = real_rates, y = `earning yield`)) +
  geom_point(size = 1, color = "blue") +
  geom_smooth(method = "lm", se = TRUE, color = "red") + ggtitle("Avant 2002")
```


Avant 2002




```
diagnostics_residus(modele.mci.before, "(corrigé, avant 2002)")
```

```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
## -0.04364 -0.01667 -0.01028  0.00000  0.01102  0.09189
```

Densité des résidus (corrigé, avant 2002)




QQ-plot (corrigé, avant 2002)




```
##  
## Asymptotic one-sample Kolmogorov-Smirnov test  
##
```

```
## data: res
## D = 0.16933, p-value = 7.71e-10
## alternative hypothesis: two-sided
```

ACF des résidus (corrigé, avant 2002)



Hétéroscédasticité (corrigé, avant 2002)



Comme attendu, le modèle corrigé trouve sa justification surtout **après** 2002.


Modèle corrigé après 2002

```
modele.mci.after <- lm(`earning yield` ~ real_rates, data_after)
summary(modele.mci.after)
```

```
##
## Call:
## lm(formula = `earning yield` ~ real_rates, data = data_after)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.027286 -0.008724  0.002246  0.008167  0.020153
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  0.0450238  0.0009913  45.421  < 2e-16 ***
## real_rates  -0.0024907  0.0003594  -6.931 1.09e-10 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.01086 on 153 degrees of freedom
## (178 observations effacées parce que manquantes)
## Multiple R-squared:  0.239, Adjusted R-squared:  0.234
## F-statistic: 48.04 on 1 and 153 DF, p-value: 1.095e-10
```

```
ggplot(data_after, aes(x = real_rates, y = `earning yield`)) +
  geom_point(size = 1, color = "blue") +
  geom_smooth(method = "lm", se = TRUE, color = "red") + ggtitle("Après 2002")
```


Après 2002




```
diagnostics_residus(modele.mci.after, "(corrigé, après 2002)")
```

```
##      Min.   1st Qu.   Median     Mean   3rd Qu.    Max.
## -0.027286 -0.008724  0.002246  0.000000  0.008168  0.020153
```

Densité des résidus (corrigé, après 2002)




QQ-plot (corrigé, après 2002)




```
##  
## Asymptotic one-sample Kolmogorov-Smirnov test  
##
```

```
## data: res
## D = 0.11517, p-value = 0.03275
## alternative hypothesis: two-sided
```

ACF des résidus (corrigé, après 2002)



Hétéroscédasticité (corrigé, après 2002)



Pour conclure : le passage au taux réel améliore le pouvoir explicatif du modèle sur la sous-période postérieure à 2002, tout en restant inadapté avant 2002 et sur la période globale.

PARTIE 3 : Modèle ARMA(p,q)

Question 8 — Le modèle ARMA(p,q)

Le modèle autorégressif à moyenne mobile (ARMA) est un modèle paramétrique (de paramètres p et q) de séries chronologiques stationnaires à courte mémoire. Une série X_t est dite ARMA(p,q) si :

$$X_t - \phi_1 X_{t-1} - \cdots - \phi_p X_{t-p} = \varepsilon_t + \theta_1 \varepsilon_{t-1} + \cdots + \theta_q \varepsilon_{t-q}$$

où $\phi_k, \theta_k \in \mathbf{C}$ et ε_t est un bruit blanc (variables décorrélées, de moyenne nulle et de variance σ_ε^2). En définissant les polynômes

$$\phi(z) = 1 - \phi_1 z - \cdots - \phi_p z^p, \quad \theta(z) = 1 + \theta_1 z + \cdots + \theta_q z^q,$$

et en notant B l'opérateur retard, l'équation se réécrit :

$$\phi(B)X_t = \theta(B)\varepsilon_t$$

Question 9 — Ordre du modèle

On choisit l'ordre (p, q) en minimisant un critère d'information (AIC/BIC) sur tous les couples $p < P$, $q < Q$ (bornes lues sur l'ACF, à partir du rang où les valeurs entrent dans l'intervalle autour de 0). On fixe $P = Q = 4$.

```

earning_yield.ts <- ts(data[["earning yield"]], frequency = 12, start = c(1960, 1))

# NB : diff = 0 ici (recherche ARMA) ; auto.arima (Q10) choisira lui-même
#       l'éventuel ordre d'intégration d.
pars <- expand.grid(ar = 1:4, diff = 0, ma = 1:4)
aic <- rep(Inf, nrow(pars))
bic <- rep(Inf, nrow(pars))

for (i in seq_len(nrow(pars))) {
  fit <- tryCatch(
    arima(earning_yield.ts, order = unlist(pars[i, 1:3]), xreg = data$rates),
    error = function(e) NULL)
  if (!is.null(fit)) { aic[i] <- AIC(fit); bic[i] <- BIC(fit) }
}

pars[which.min(aic), ] # meilleur modèle au sens de l'AIC

##   ar diff ma
## 16   4    0  4

pars[which.min(bic), ] # meilleur modèle au sens du BIC

##   ar diff ma
##  2   2    0  1

```

On retient la sélection par BIC (approche parcimonieuse), qui donne $p = 2$, $q = 1$. Le modèle est donc :

$$X_t - \phi_1 X_{t-1} - \phi_2 X_{t-2} = \varepsilon_t + \theta_1 \varepsilon_{t-1}$$


Une part intégrée ($d = 1$, modèle ARIMA) se justifie pour éliminer la tendance de la série, nettement visible sur le tracé initial.

Question 10 — Estimation du modèle

```
# Découpage apprentissage / test
y_train <- window(earning_yield.ts, 1960, c(2015, 12)) # 672 mois
y_test  <- window(earning_yield.ts, c(2016, 1), c(2019, 3)) # 39 mois

fit_ARIMA <- auto.arima(y_train, xreg = data[1:672, "rates"])
forecast_ARIMA <- forecast(fit_ARIMA, xreg = data[673:711, "rates"])
plot(forecast_ARIMA)
```

Forecasts from Regression with ARIMA(1,1,2)(0,0,1)[12] errors




Question 11 — Prévvision et intervalle de confiance à 95 %

```
upper_train_ARIMA <- fitted(fit_ARIMA) + 1.96 * sqrt(fit_ARIMA$sigma2)
lower_train_ARIMA <- fitted(fit_ARIMA) - 1.96 * sqrt(fit_ARIMA$sigma2)
upper_test_ARIMA  <- forecast_ARIMA$upper[, 2]
lower_test_ARIMA  <- forecast_ARIMA$lower[, 2]


# Série complète + prévision
plot(earning_yield.ts, type = "n", main = "Série et prévision")
lines(earning_yield.ts)
lines(forecast_ARIMA$mean, col = "red")
```

Série et prévision




```
# Apprentissage : série, ajustement et IC à 95 %
plot(y_train, type = "n", ylim = range(lower_train_ARIMA, upper_train_ARIMA),
     main = "Apprentissage et IC 95 %")
polygon(c(time(y_train), rev(time(y_train))),
        c(upper_train_ARIMA, rev(lower_train_ARIMA)),
        col = rgb(0, 0, 0.6, 0.2), border = FALSE)
lines(y_train)
lines(fitted(fit_ARIMA), col = "red")
```

Apprentissage et IC 95 %




```
# Test : prévision seule
plot(y_test, type = "n", main = "Test : observé vs prévision")
lines(y_test)
lines(forecast_ARIMA$mean, col = "red")
```



```
# Test : prévision + IC à 95 %
plot(y_test, type = "n", ylim = range(upper_test_ARIMA, lower_test_ARIMA),
     main = "Test : prévision et IC 95 %")
polygon(c(time(y_test), rev(time(y_test))),
       c(upper_test_ARIMA, rev(lower_test_ARIMA)),
       col = rgb(0, 0, 0.6, 0.2), border = FALSE)
lines(y_test)
lines(forecast_ARIMA$mean, col = "red")
```

Test : prévision et IC 95 %



Le modèle paraît plutôt bon sur la plage de prévision.

Question 12 — Comparaison RMSE / MAE

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|, \quad RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

```
RMSE <- function(error) sqrt(mean(error^2))
MAE <- function(error) mean(abs(error))

# Modèle 1 : ARIMA sélectionné par auto.arima
predictions_ARIMA <- forecast_ARIMA$mean
c(RMSE = RMSE(predictions_ARIMA - y_test), MAE = MAE(predictions_ARIMA - y_test))

##          RMSE          MAE
## 0.002611064 0.001960378

# Modèle 2 : ARMA(2,1) retenu en Question 9
fit_ARMA <- arima(y_train, order = unlist(pars[2, 1:3]), xreg = data[1:672, "rates"])
predictions_ARMA <- predict(fit_ARMA, newxreg = data[673:711, "rates"])$pred
c(RMSE = RMSE(predictions_ARMA - y_test), MAE = MAE(predictions_ARMA - y_test))

##          RMSE          MAE
## 0.002785972 0.002010940
```

Au vu de ces critères, le premier modèle (auto.arima) est le plus performant.

Question 11 bis — Test de Diebold-Mariano

On utilise `dm.test` pour comparer la performance prédictive des deux modèles.

```
dm.test(e1 = fit_ARMA$residuals, e2 = forecast_ARIMA$residuals,
        alternative = "less", h = 1)

##
## Diebold-Mariano Test
##
## data: fit_ARMA$residualsforecast_ARIMA$residuals
## DM = 0.27176, Forecast horizon = 1, Loss function power = 2, p-value =
## 0.6071
## alternative hypothesis: less
```

PARTIE 4 : Stabilité du modèle

On s'intéresse à la stabilité du coefficient β de l'équation du Fed model :

$$\frac{E_t}{P_t} = \alpha + \beta r_t$$

Question 13 — Estimation glissante


```
begin <- 1960
end <- 1990
n_fen <- 2019 - end          # nombre de fenêtres
beta <- numeric(n_fen)
beta_inf <- numeric(n_fen)
beta_sup <- numeric(n_fen)

earning_yield <- ts(data[["earning yield"]], start = c(1960, 1), frequency = 12)
rates_ts <- ts(data$rates, start = c(1960, 1), frequency = 12)

for (i in seq_len(n_fen)) {
  y <- window(earning_yield, start = begin + i, end = end + i)
  x <- window(rates_ts, start = begin + i, end = end + i)
  reg <- lm(y ~ x)
  conf <- confint(reg, level = 0.95)
  beta[i] <- reg$coefficients[2]
  beta_inf[i] <- conf[2, 1]
  beta_sup[i] <- conf[2, 2]
}

plot(beta, xlab = "indice de la période glissante", ylab = "beta estimé",
     main = "Estimation glissante de beta", ylim = range(beta_inf, beta_sup))
points(beta_inf, lwd = 2, col = "red")
points(beta_sup, lwd = 2, col = "blue")
```

Estimation glissante de beta




L'estimation de β ne reste pas constante d'une fenêtre à l'autre : des changements de structure semblent se manifester. Les intervalles de confiance à 95 % confirment qu'il ne s'agit pas de simple bruit : les bornes basses des premières fenêtres sont largement au-dessus des bornes hautes des dernières.

Question 14 — Test CUSUM

Le test CUSUM repose sur une estimation récursive des coefficients. Sous l'hypothèse nulle (absence de changement structurel), le processus des résidus récursifs tend vers un processus de Wiener. On rejette H_0 si le processus empirique s'écarte trop fortement des bornes de confiance à 95 %.

```
ocus <- efp(earning_yield ~ rates_ts, type = "OLS-CUSUM")
plot(ocus)
```

OLS-based CUSUM test



Les fluctuations excèdent par endroits les bornes de confiance à 95 % : on rejette H_0 . Il y a donc un changement structurel, ce qui rejoint la conclusion de la question précédente.

Mabrouk Chetouane
Université Paris Dauphine
BFT - Investment Manager

Ecole Centrale de Paris - Supelec
Séries temporelles appliquées
Cours de Pascal Bondon
03 mars 2020

Modèle $ARMA(p, q)$ et Méthode des moindres carrés ordinaires

Votre fichier devra s'intituler "NOM1 NOM2 - CENTRALE - 0320.(pdf)" et il en va de même pour l'objet du mail. La date limite d'envoi est le dimanche 8 mars à 00h00. Veuillez soigner la présentation de vos résultats ainsi que la rédaction (en Tex uniquement). Il vous est également demandé de joindre vos codes dans un fichier R. L'adresse pour l'envoi du document est mabrouk.chetouane@gmail.com

Exercice : modèle d'arbitrage

Cadre : Le Fed model est un modèle empirique que l'on peut classer dans la catégorie de modèle d'arbitrage simple. Le Fed model repose sur l'idée qu'il existe une relation d'arbitrage entre la rémunération d'une obligation d'état, jugée sans risque, et le taux de rendement d'une action plus risquée. Le prolongement de cette logique induit l'existence d'une relation d'équilibre entre les deux variables. L'équation ci-dessous permettrait de décrire cette relation :

$$\frac{E_t}{P_t} = \alpha + \beta \cdot r_t \quad (1)$$

Le modèle économétrique est donné par la relation ci-dessous :

$$\frac{E_t}{P_t} = \alpha + \beta \cdot r_t + \epsilon_t \quad (2)$$

où E_t désigne les earnings d'un indice ou d'une entreprise, P_t le prix de cette action ou de l'indice, r_t un taux sans risque et ϵ_t le terme d'erreur du modèle et on suppose $\epsilon_t \sim \mathcal{N}(0, \sigma_\epsilon^2)$. On supposera des indices actions pour des raisons de simplicité (ici le S&P500) et nous considérons un taux de rendement d'une obligation d'état à 10 ans en guise de taux sans risque.

Partie 1 : Estimation du modèle

Question 1 - Calculer le earning yield de l'indice du S&P500. Tracer les deux courbes en faisant apparaître les dates sur l'axe des abscisses. Tracer un nuage de points liant le earning yield au taux de rendement des obligations à 10 ans. L'ajustement linéaire est-il justifié ? Utiliser la commande "**abline**" pour tracer cet ajustement.

Question 2 - Rappeler le principe de la méthode des moindres carrés ordinaires. Rappeler les hypothèses sous-jacente de l'estimateur des MCO.

Question 3 - Montrer que l'application des moindres carrés ordinaires à l'équation 2 permet de parvenir au résultat suivant:

$$\hat{\alpha} = \left(\frac{\bar{E}}{\bar{P}} \right) - \hat{\beta} \bar{r} \quad (3)$$

$$\hat{\beta} = \frac{Cov\left(\frac{E}{P}, r\right)}{\sigma_r^2} \quad (4)$$

Démontrer que $\lim_{T \rightarrow \infty} V[\hat{\beta}] = 0$.

Question 4 - A l'aide la fonction "lm" du logiciel R, estimer par les MCO les coefficients de l'équation 2. Commenter vos résultats en particulier le signe du coefficient et sa significativité. Qu'indiquent les statistiques de Student et de Fisher ainsi que le coefficient de détermination ?

Question 5 - Réaliser un étude complète des résidus estimés : tracer leur densité, étudier leur normalité et vérifier l'existence/l'absence d'autocorrélation et d'hétéroscédasticité. Quel serait l'estimateur le plus adéquat si l'on venait à détecter de l'hétéroscédasticité dans les résidus. Détailler votre réponse.

Question 6 - L'observation des séries et du nuage de point laisse penser qu'une rupture s'es produite. A l'aide de la commande "window " découper votre dataset en deux parties : depuis 1961 jusqu'à décembre 2001 puis de janvier 2002 à mars 2019. Représenter côte à côte les nuages de points de ses deux sous-échantillons. Que constatez-vous? Estimer le modèle décrit par l'équation 2 pour chacune des sous-périodes. Commenter vos résultats. Existe-t-il des familles de modèles capables de prendre en charge ce type de configuration de données.

Partie 2: Estimation d'une nouvelle spécification et comparaison

Le *Fed model* comprend cependant une limite dans sa spécification. En effet, ses auteurs tentent d'expliquer le comportement d'une variable réelle $E_{i,t}/P_{i,t}$ en utilisant un taux de rendement nominal. Pour corriger cette limite, on décide de calculer un taux d'intérêt réel en déflatant ce dernier de la croissance de l'indice des prix à la consommation (CPI) sur sur 12 mois.

$$\frac{E_i}{P_i} = \alpha + \beta \cdot (r_i - \pi_t) + \epsilon_t \quad (5)$$

$$\frac{E_t}{P_t} = \alpha + \beta \cdot rr_t + \epsilon_t \quad (6)$$

Question 7 - Calculer le taux d'intérêt réel. Estimer par la méthode des moindres carrés ordinaires cette nouvelle spécification sur l'ensemble de la période d'une part puis sur les deux sous périodes d'autre part. Ce changement de spécification améliore-t-il le pouvoir explicatif du modèle notamment sur la seconde période? Justifier votre réponse.

Partie 3: Estimation d'une nouvelle spécification : modèle $ARMA(p, q)$

On propose de comparer ce modèle augmenté à une approche naïve basée sur un modèle $ARMA(p, q)$ sur l'ensemble de période d'étude c'es à dire depuis 1961.

Question 8 - Présenter le modèle ARMA et ses principales propriétés de manière précise et succincte.

Question 9 - Identifier l'ordre du modèle ARMA à l'aide de deux méthodes différentes (on privilégiera un approche parcimonieuse). L'introduction d'une partie intégrée dans votre modèle ARMA (soit un modèle de type ARIMA) vous paraît nécessaire. Pourquoi?

Question 10 - Estimer le modèle identifié à l'aide de la fonction "auto.arima" et vérifier la qualité de votre estimation.

Question 11 - Effectuer une prévision à l'aide de la commande "predict" sur horizon de trois périodes. Donner l'intervalle de confiance de votre prévision à 95% et tracer le sur le même graphique que votre prévision.

Une manière de sélectionner un modèle estimé consiste à évaluer sa capacité prédictive. On a alors recours à la Root Mean Square Error et de la Mean Absolute Error.

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$
$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

Question 12 - Comparer les deux derniers modèles estimés en utilisant ces deux critères. Quel est celui qui affiche la meilleure performance?

Question 11 bis : - Une autre manière de comparer la qualité prédictive de deux modèles économétriques consiste à mettre en oeuvre le test de Diebold et Mariano (1995). On note $r_{i,t+h|t}^a$ la prévision du taux de rendement issue du Fed model (première version) et $r_{i,t+h|t}^b$ celle issue de la seconde spécification, pour $t = t_0, \dots, T$. Dès lors on a

$$\epsilon_{i,t+h|t}^a = r_{i,t+h} - r_{i,t+h|t}^a$$

$$\epsilon_{i,t+h|t}^b = r_{i,t+h} - r_{i,t+h|t}^b$$

On définit une fonction de perte, notée $L(r_{i,t+h}, r_{i,t+h|t}^j) = L(\epsilon_{i,t+h|t}^j)$, avec $j = a, b$. On retient habituellement la fonction de perte suivante $L(\epsilon_{i,t+h|t}^j) = (\epsilon_{i,t+h|t}^j)^2$. Pour savoir si un modèle est plus performant qu'un autre modèle, on teste alors l'hypothèse nulle suivante:

$$H_0 : \mathbb{E} [L(\epsilon_{i,t+h|t}^a)] = \mathbb{E} [L(\epsilon_{i,t+h|t}^b)]$$

contre l'hypothèse alternative

$$H_0 : \mathbb{E} [L(\epsilon_{i,t+h|t}^a)] \neq \mathbb{E} [L(\epsilon_{i,t+h|t}^b)]$$

Le test de Diebold et Mariano (1995) est basé sur la différence des fonctions de perte. Formellement on a,

$$d_t = L(\epsilon_{i,t+h|t}^a) - L(\epsilon_{i,t+h|t}^b)$$

L'hypothèse nulle devient alors $H_0 = \mathbb{E}[d_t] = 0$. La statistique de Diebold et Mariano (1995) est donnée par

$$S_{DM} = \frac{\bar{d}}{\sqrt{\hat{\omega}}} \sim \mathcal{N}(0, 1) \text{ avec } \bar{d} = \frac{1}{T_0} \sum_{t=t_0}^T d_t$$

$$\text{avec } \hat{\omega} = \gamma_0 + 2 \sum_{j=1}^{\infty} \gamma_j \text{ et } \gamma_j = \text{cov}(d_t, d_{t-j})$$

Diebold et Mariano (1995) montrent que sous l'hypothèse nulle (prévisions équivalentes) alors $S_{DM} \sim \mathcal{N}(0, 1)$. On rejettera l'hypothèse nulle, au seuil de 5% si $|S_{DM}| > 1.96$.

Développer une routine sous R permettant de calculer la statistique de test puis de conclure sur la qualité prédictive du modèle.

Partie 4: Stabilité du modèle

On s'intéresse désormais à la stabilité du coefficient de l'équation du *FED model*. Plusieurs outils sont disponibles pour juger de la stabilité du modèle autrement dit des coefficients estimés :

1. sur une estimation récursive des coefficients de l'équation. Autrement dit, on estime le modèle en ajoutant à chaque nouvelle régression une observation supplémentaire.
2. sur une estimation glissante du paramètre où l'on sélectionne une période d'estimation que l'on décale d'une période.

Question 13 - A l'aide d'une routine que vous développez sous R, estimer les coefficients conformément à la méthode glissante. Tracer les courbes des coefficients β_i estimés ainsi que leur intervalle de confiance au seuil de 95%¹. Commenter.

La seconde étape pour étudier la stabilité globale d'un modèle consiste à analyser les résidus issus des estimations récursives (cf. étape 1). Ces résidus sont ensuite utilisés pour calculer la statistique CUSUM qui permet de conclure en matière sur la stabilité du modèle estimé.

Question 14 - Présenter le test CUSUM. Implémenter le test de CUSUM² et commenter vos résultats .

Bon Courage

1. L'intervalle de confiance au niveau $\alpha = 0.95$ pour X_{t+h} peut être calculé en utilisant la fonction `"predict"` et l'option `"conf"`.

2. Pour aller plus vite, charger puis installer le package `strucchange`. Dans votre scripte, `install.packages("strucchange")` ; `library("strucchange")`. Le test CUSUM y est directement implémenté.