

Quantification des Incertitudes dans les Simulations Numériques

Ilyas Hanine

Avril 2020

1 Présentation du modèle

Le modèle est celui d'un drone catapulté du sol sans moteur. Les équations régissant son mouvement sont les suivantes :

$$\begin{cases} m\ddot{p} = -m\beta_3 e_z + \|\dot{p} - s_w\| (e_x (-\beta_1 \alpha_x - \beta_2 \alpha_z) + e_z (-\beta_1 \alpha_z - \beta_2 \alpha_x)) \\ \alpha_x = \langle \dot{p} - s_w, e_x \rangle, \alpha_z = \langle \dot{p} - s_w, e_z \rangle \\ \dot{p}(t=0) = s_0, p(t=0) = (0, 0) \end{cases}$$

- $p(t) = p_x(t)e_x + p_z(t)e_z$ la position au temps t du centre de gravité du système,
- m la masse du drone,
- $s_w(t)$ la vitesse du vent à l'instant t
- $s_0 = u_0 (\cos(\theta_0)e_x + \sin(\theta_0)e_z)$ la vitesse initiale avec (θ_0) l'angle initial de lancement et v_0 la vitesse de lancement.
- β_1 et β_2 les coefficients de portance et de trainée respectivement.
- β_3 la gravité.

Les 7 paramètres d'entrées sont supposés indépendants et varient uniformément. Ils sont regroupés dans le vecteur $x = (v_0, \theta_0, m, L, \beta_1, \beta_2, \beta_3)$

Dans la suite, la quantité d'intérêt est $y_{max}(x)$, la distance horizontale parcourue par le drone.

2 Propagation d'incertitudes

2.1 Étude en tendance centrale

1. En exécutant le code fourni, on obtient pour la quantité d'intérêt le résumé statistique de la figure 1

```
> n = 200
> X = TirageX(n)
> # Propagation des incertitudes
> Y = code.vect(X)
> # Résumé
> summary(Y)
  Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
 487.0  679.3   767.9   792.2   888.5  1402.9
```

FIGURE 1 – Résumé statistique de $y_{max}(x)$

2. La quantité d'intérêt y_{max} est positive strictement, c'est une distance. On déduit qu'elle ne peut suivre une loi gaussienne malgré un histogramme et une densité qui pourrait le faire penser en figure 2. Le qqplot de la figure 3 laisse penser que la distribution n'est pas normale (en particulier les queues de distribution). On peut vérifier cette intuition en réalisant un test de Shapiro-Wilk pour lequel on obtient une p-value de 0.0003063 inférieur à 0.05, ie que l'échantillon ne suit pas une loi normale avec une confiance de 95%.




FIGURE 2 – Histogramme de $y_{max}(x)$




FIGURE 3 – QQplot de $y_{max}(x)$

3. En utilisant les fonctions de R (*mean* et *sd*), on obtient une moyenne de 792,1784 m et un écart type de 155,5953 m. Par théorème central limite ($n=200 > 30$), on peut appliquer les intervalles de confiance classique pour les quantités désirées dans le cas de distributions normales. Ainsi, on obtient pour la moyenne l'intervalle [770.4824; 813.8743] et pour l'écart type : [137.7060; 171.6299]

4. Réalisé lors du TP-3, on établit un IC bootstrap pour le kurtosis en utilisant la routine qui se base sur les quantiles de la densité estimée par bootstrap. On obtient l'intervalle suivant : [2.263385; 4.811015]. Le kurtosis est positif et relativement élevé. En effet, en traçant l'histogramme en figure 1, on observe un *étalement* marqué des échantillons sur la droite.

2.2 Quantiles

1. En figure 4, le quantile empirique à 95% vaut 1058.757.

2. Avec un taux de confiance à 90, 95 et 99%, on obtient un quantile empirique à 95% respectivement de 1123.364, 1140.017 et 1143.298. Comme on pouvait s'y attendre plus le taux de confiance

```

> # quantile empirique
> qY95 = quantile(Y, probs=0.95)
> qY95
      95%
1058.757

```

FIGURE 4 – Quantile empirique

exigé est élevé plus le quantile est élevé puisque on s'attend à ce que qu'empiriquement le quantile estimé avec l'échantillon ait plus de chance d'être inférieur à cette borne fournie par la méthode de Wilks. En figure 5, le code correspondant.

```

> # Quantile de Wilks, niveau de confiance 99%
> qY95_wilks_99 = wilks.quantile(alpha=0.99, beta=0.99, datay, bilateral=FALSE)
> qY95_wilks_99
Supper
[1] 1143.298
$min
[1] 99

```

FIGURE 5 – Méthode de Wilks

3. La méthode de Wilks fournit le nombre minimum d'échantillons nécessaires à l'obtention d'un majorant de la valeur d'un quantile avec un certain taux de confiance β . Par exemple pour un taux de confiance à 90%, $n_{min} = 45$.

4. On cherche dans cette question, à répondre à la question inverse. Sachant que $n = 200$, quel est au mieux le taux de confiance que l'on pourrait obtenir pour l'estimation du quantile à 95%. En utilisant la fonction *uniroot* de R, on obtient $\beta = 0.9999624$.

2.3 Évènements rares

L'objectif de cette partie est d'estimer $P(y_{\max} \geq 1350)$.

Nous allons mettre en œuvre des méthodes approchées pour l'estimation de cette probabilité. Précisément la méthode FORM basée sur l'approximation de la surface de défaillance (ici la défaillance est équivalente à une distance parcourue par le drone trop élevée) par un hyper plan.

Il s'agit de résoudre un problème d'optimisation de minimisation de distance dans l'espace des variables centrées réduites sous la condition qu'une certaine fonction de défaillance $g=0$ (son approximation au premier ordre dans le cadre de la méthode FORM) en ce point.

Cette méthode a l'avantage d'être peu coûteuse en simulations et d'être très facilement réalisable sur R (code fourni dans le TP-5 - nécessite cependant le (re)codage pour le passage de l'espace physique à l'espace gaussien en figure 6). Par contre il s'agit d'une méthode approchée, donc aucune réelle garantie de résultat n'est fournie par la méthode et en outre elle ne fournit pas d'intervalle de confiance pour la probabilité recherchée.

Finalement on obtient $P(y_{\max} \geq 1350) = 0.004$

```

passage_U_X_projet = function(U){
  X = U
  X[,1] = qunif(pnorm(U[,1]), min=100, max=125)
  X[,2] = qunif(pnorm(U[,2]), min=pi/10, max=pi/5)
  X[,3] = qunif(pnorm(U[,3]), min=1, max=2)
  X[,4] = qunif(pnorm(U[,4]), min=1, max=2)
  X[,5] = qunif(pnorm(U[,5]), min=0.05, max=0.2)
  X[,6] = qunif(pnorm(U[,6]), min=0.01, max=0.11)
  X[,7] = qunif(pnorm(U[,7]), min=9.805, max=9.815)
  return(X)
}

```

FIGURE 6 – Code de passage de l'espace physique à l'espace standard

3 Analyse de sensibilité

Pour estimer les indices de Sobol, qui quantifie la sensibilité d'une variables de sortie aux variables d'entrée, nous allons passer par un métamodèle. Pour rappel, le ième indice de sensibilité de premier ordre est défini par :

$$S_i = \frac{Var[\mathbf{E}[Y|X_i]]}{Var[Y]}$$

3.1 Métamodélisation

On est clairement dans le cas d'un modèle hautement non-linéaire, non-monotone. De plus $n = 200 > 10d$ où $d = 7$, nous allons donc mettre en œuvre des méthodes basées sur la décomposition de la variance

1. La routine *factDesign* permet d'établir le plan factoriel complet (plan de Monte Carlo) dont les points sont répartis suivant les lois uniformes de l'énoncé. Ce sont les plans les plus "simples", mais ils sont trop coûteux en nombre d'expériences quand la dimension est élevé. Pour la suite nous avons faire le choix des plans LHS (Latin Hypercube Sampling). Ces plans ne sont pas uniques et plusieurs critères d'optimisation existent : les deux plus connus sont le minimax et le maximin. Nous faisons le choix du maximin ie que l'on cherche à maximiser la distance minimale entre 2 points du plan d'expérience. La routine utilisée sur R se trouve sur la figure 7. Le critère obtenu vaut 0.532029462408701 est optimal par rapport aux autres routines. Le plan est en figure 8

```
x_rand_LHS = lhsDesign(n=100, dimension=7, randomized=TRUE)$design
x_LHS_maximin = maximinSA_LHS(x_rand_LHS)$design
```

FIGURE 7 – Routine plan LHS optimal




FIGURE 8 – Plan LHS critère maximin

2. On fait le choix d'une métamodélisation par processus gaussien en utilisant la fonction *km* à partir du plan LHS obtenu à la question précédente. On visualise en figure 9 les résultats de l'apprentissage de notre métamodèle et d'un métamodèle linéaire. Clairement le métamodèle gaussien semble meilleur (en rouge sur la figure 9).

Pour véritablement caractériser l'optimalité de notre choix de métamodélisation, nous allons utiliser le critère $Q2$ calculé sur 100 prédictions (variance de la différence de prédiction sur la variance de la réponse véritable du modèle). De la même manière que précédemment, on visualise les prédictions sur la figure 10 (en rouge le métamodèle gaussien) et on obtient un score $Q2_{ml} = 0.9100244$ et

$Q2_{gaussien} = 0.9919498$. Le choix du métamodèle gaussien est bien justifié, et le modèle est prédictif ($Q2_{gaussien} \simeq 1$).




FIGURE 9 – Apprentissage d'un métamodèle linéaire et gaussien




FIGURE 10 – Comparaison des métamodèles sur 100 prédictions

On peut ensuite s'intéresser à la confiance dans la prédiction de notre métamodèle en mettant en œuvre une procédure de validation croisée de type "Leave-One-Out" (LOO). La figure 11 permet d'apprécier visuellement la confiance de prédiction en notre modèle avec la procédure LOO. Le fait que les points noirs, ie les prédictions LOO, soient tous dans l'intervalle de confiance à 95% - tracé en rouge - montre que notre modèle a une bonne capacité prédictive.

3.2 Indices de Sobol

1. Pour le calcul des indices de Sobol, nous faisons le choix d'une estimation par Monte-Carlo. Ainsi d'après le cours $n \simeq 1000$. La fonction R utilisée est *soboljansen*. Le coût total N de la routine est $N = (d + 2)n = 9000$. On fait le choix de réaliser 100 échantillons bootstrap.

2. En figure 12 et figure 13, on trouvera les résultats de l'estimation des indices de Sobol. Il y a des résultats qui sont plutôt intuitifs : la portance et la vitesse initiale sont les variables d'entrée qui explique le plus la variance de variable de sortie alors que la gravité ne semble pas beaucoup influencer sur $y_{max}(x)$. Cela peut être dû en partie à la faible plage de variation du paramètre. La masse et la trainée joue un rôle similaire dans la sensibilité du paramètre de sortie. Finalement la longueur L , n'intervient même pas du tout dans les équations du modèle, il est clair que son indice de Sobol associé est nul.




FIGURE 11 – Confiance du modèle gaussien sur 100 prédictions LOO




FIGURE 12 – Résultats ASG




FIGURE 13 – Résultats ASG plus précis

Quantification des Incertitudes dans les Simulations Numériques

Projet

Année 2019-2020

Ce projet, à réaliser en solo, est à rendre au plus tard le 10/04/2020. Vous devrez me fournir par mail claire.cannamela@gmail.com un rapport comportant :


- l'explication de la démarche,
- les résultats obtenus synthétisés sous forme de figure ou de tableaux,
- l'interprétation des résultats,
- la justification du choix de la méthode utilisée quand c'est nécessaire
- et tout élément que vous jugez pertinent.

Tout a déjà été fait en TP, ainsi je souhaite que vous mettiez l'accent sur l'interprétation et les justifications.

Je vous joins un script à compléter `projet.R`, dans lequel il y a les fonctions à charger, des packages utiles, un exemple d'utilisation des fonctions utiles au modèle et quelques indications.

1 Présentation du modèle

On s'intéresse à la prédiction de la trajectoire d'un drone sans moteur catapulté du sol.



1.1 Le modèle

Les équations régissant cette trajectoire s'écrivent :

$$\begin{cases} m\ddot{\mathbf{p}} = -m\beta_3\mathbf{e}_z + \|\dot{\mathbf{p}} - \mathbf{s}_w\| (\mathbf{e}_x(-\beta_1\alpha_x - \beta_2\alpha_z) + \mathbf{e}_z(-\beta_1\alpha_z - \beta_2\alpha_x)), \\ \alpha_x = \langle \dot{\mathbf{p}} - \mathbf{s}_w, \mathbf{e}_x \rangle, \alpha_z = \langle \dot{\mathbf{p}} - \mathbf{s}_w, \mathbf{e}_z \rangle, \\ \dot{\mathbf{p}}(t=0) = \mathbf{s}_0, \mathbf{p}(t=0) = (0,0), \end{cases}$$

- $\mathbf{p}(t) = p_x(t)\mathbf{e}_x + p_z(t)\mathbf{e}_z$ la position au temps t du centre de gravité du système,
- m la masse du drone,
- $\mathbf{s}_w(t)$ la vitesse du vent à l'instant t ,
- $\mathbf{s}_0 = v_0(\cos(\theta_0)\mathbf{e}_x + \sin(\theta_0)\mathbf{e}_z)$ la vitesse initiale avec (θ_0) l'angle initial de lancement et v_0 la vitesse de lancement.
- β_1 et β_2 les coefficients de portance et de trainée respectivement.
- β_3 la gravité.

En utilisant un schéma de résolution explicite, le système d'équations peut être résolu numériquement.

1.2 Les paramètres d'entrée

Les paramètres d'entrées sont au nombre de 7, ils sont supposés indépendants. ils sont regroupés dans le vecteur $\mathbf{x} = (v_0, \theta_0, m, L, \beta_1, \beta_2, \beta_3)$.

Pour simplifier le problème, on considère que tous les paramètres varient uniformément. Les plages de variations sont synthétisées dans le tableau suivant :


paramètres	v_0	θ_0	m	L	β_1	β_2	β_3
unité	ms^{-1}	rad	kg	m	-	-	ms^{-2}
min	100	$\pi/10$	1	1	0.05	0.01	9.805
max	125	$\pi/5$	2	2	0.2	0.11	9.815

Le vent est un paramètre aléatoire non contrôlable modélisé par $\{\mathbf{s}_w(t), t \geq 0\}$ (*i.e.* interne au modèle). Sa moyenne et son écart-type sont fixé dans le modèle.

1.3 Quantité d'intérêt

Pour $\mathbf{x}$ fixé, toute la trajectoire du drone est délivrée par le code de calcul. Cependant, pour ce projet, cette information sera réduite à la quantité d'intérêt suivante :

- $y_{\max}(\mathbf{x})$ la distance parcourue par le drone (en rouge sur la figure ci-dessous),



1.4 Utilisation du code de calcul en pratique

Les fonctions nécessaires à la résolution du problème sont regroupées dans le fichier `cas_balistique.R`. Celles utiles pour ce projet sont les suivantes :

- `TirageX(n)` qui permet de générer n réalisations aléatoires selon la loi de X .

```
1 > Z = TirageZ(2); Z
2           x1           x2           x3           x4           beta1           beta2           beta3
3 [1,] 100.2339 0.4164967 1.992178 1.773132 0.16954534 0.02886791 9.806545
4 [2,] 114.4915 0.4723712 1.464411 1.206392 0.07032138 0.07652172 9.814231
```

- `code.vect(X)` : c'est le code de calcul qui retourne la quantité d'intérêt $y_{\max}(\mathbf{x})$. Il prend en entrées les 7 paramètres d'entrée regroupés dans le vecteur $\mathbf{x}$.

```
1 > code.vect(X)
2           [,1]           [,2]
3 [1,] 571.79364 1044.846
4 [2,] 76.44219 189.774
```

2 Propagation d'incertitudes

2.1 Étude en tendance centrale

Nous cherchons à estimer la moyenne de la distance parcourue par le drone ainsi que sa dispersion par une méthode de Monte Carlo.

1. Générer un échantillon aléatoire de taille $n = 200$ de réalisations des 7 paramètres d'entrées. Propager les incertitudes dans le modèle du lancement de drone et faire un résumé statistique de l'échantillon de la distance parcourue obtenu $(\mathbf{y}_{\max,i})_{i=1,\dots,n}$.
2. Tracer l'histogramme de cet échantillon. Cet échantillon pourrait-il être gaussien ? Confirmer (ou pas) par un test statistique et par des graphiques appropriés.
3. Calculer une estimation de sa moyenne et de son écart-type ainsi que les intervalles de confiance à 95% associés à ces quantités statistiques. Justifier vos choix.
4. Estimer un intervalle de confiance à 95% pour le kurtosis de $\mathbf{y}_{\max}$ avec une méthode de bootstrap. Analyser.

2.2 Quantiles

Afin de lancer le drone dans un endroit de longueur adéquate nous cherchons à estimer certains quantiles assez élevés (entre 90% et 99%) de la distance parcourue. Pour ce faire nous allons utiliser le même échantillon que celui de l'exercice précédent.

1. Estimer le quantile empirique 95% de $\mathbf{y}_{\max}$. Quelle confiance peut-on associer à ce résultat ?
2. Estimer le quantile à 95% de $\mathbf{y}_{\max}$ avec de la méthode de Wilks pour des niveaux de confiance de 90%, 95% et 99%. Comparer-les avec le résultat précédent.
3. Que propose le quantile de Wilks par rapport au quantile empirique ? Quels sont les avantages et inconvénients de la méthode de Wilks ?
4. Quelle confiance peut-on associer au mieux à l'estimation du quantile à 95% de $\mathbf{y}_{\max}$ avec de la méthode de Wilks ?

2.3 Événements rares

L'objectif de cette partie est d'estimer $P(\mathbf{y}_{\max} \geq 1350)$. En effet, on dispose d'un grand terrain de 1350 m, bordé d'une forêt très dense, et on souhaiterait estimer le risque de perdre le drone, c'est-à-dire le risque que la distance parcourue par le drone soit supérieure à la longueur du terrain.

1. Pour estimer $P(\mathbf{y}_{\max} \geq 1350)$, le nombre d'appels au modèle n'est pas contraint. Vous pouvez utiliser la méthode que vous souhaitez.
2. Expliquez le principe de la méthode retenue. Justifiez votre choix bien sûr. Quels sont les avantages et inconvénients de cette méthode ? Combien a-t-elle coûté en nombre d'appels au modèle ? etc

3 Analyse de sensibilité

On souhaite estimer les indices de Sobol, malheureusement ce modèle est trop coûteux pour le faire directement. Le passage par un métamodèle est requis.

3.1 Métamodélisation

1. Construire un plan d'expériences de 100 points et évaluer la réponse d'intérêt $y_{\max}$. Vous avez le choix sur le plan (Monte Carlo, LHS, plan optimisé, etc?), mais vous devez justifier votre choix (calculs de critères, graphe, etc)
2. Construire un métamodèle de $y_{\max}$ à partir des résultats précédents. Vous avez également le choix sur le type de métamodèle, mais devez le valider! Ce métamodèle est-il prédictif? Des graphiques (et commentaires associés) de validation seraient appréciés.

3.2 Indices de Sobol

1. Calculer les indices de Sobol du premier ordre et totaux de la sortie (à partir du métamodèle) en utilisant une taille d'échantillon adaptée et en contrôlant la précision de vos estimations. Combien d'appels au métamodèle a demandé ces estimations?
2. Analyser. Utiliser les outils appropriés pour interpréter les résultats. Y-a-t-il des interactions significatives entre les variables d'entrée?